Detecção de Ataques de False Data Injection em Pelotões Veiculares Usando Reinforcement Learning

César de Paula Morais[1]

[1]Departamento de Ciência da Computação – Universidade Federal de Minas Gerais (UFMG)
Orientador: Prof. Dr. Luiz Filipe Menezes Vieira
Tipo de Pesquisa: Mista

cesar.morais@dcc.ufmg.br

1. Introdução

1.1. Problema a ser investigado

A crescente adoção de sistemas veiculares conectados e autônomos, particularmente em configurações de pelotões veiculares, representa uma das principais tendências na evolução dos sistemas de transporte inteligente. No entanto, a dependência de comunicações inter-veiculares introduz vulnerabilidades críticas de segurança cibernética que podem comprometer tanto a eficiência operacional quanto a segurança dos ocupantes.

O problema central investigado neste projeto é a **detecção de ataques de False Data Injection (FDI) em pelotões veiculares**. Estes ataques consistem na inserção maliciosa de dados falsos nas comunicações entre veículos, podendo manipular informações críticas como velocidade, aceleração e posição. Tais manipulações podem induzir comportamentos inadequados no pelotão, como frenagens bruscas desnecessárias ou acelerações perigosas, potencialmente resultando em colisões e comprometimento da estabilidade do sistema.

1.2. Trabalho Desenvolvido Anteriormente

Este projeto tem como ponto de partida a pesquisa desenvolvida na disciplina de Redes Sem Fio, onde foi implementada uma abordagem inicial baseada em Reinforcement Learning para detecção de ataques FDI. O trabalho anterior estabeleceu:

- **Ambiente de simulação** completo utilizando Plexe, SUMO e OMNeT++ para modelagem realística de pelotões veiculares;
- **Implementação controlada de ataques FDI** através de modificações no código-fonte do framework, permitindo a injeção de dados falsos em mensagens beacon;
- Geração de **dataset balanceado com aproximadamente 9.000 amostras** contendo cenários com e sem ataques;
- **Modelo de detecção** baseado em PPO (Proximal Policy Optimization) treinado offline.

Os resultados preliminares, embora demonstrem a viabilidade da abordagem, revelaram limitações significativas: **acurácia de 52,6%, sensibilidade de 69,1% e especificidade de apenas 35,6%**. Estes indicadores são insuficientes para aplicações práticas em sistemas de segurança veicular, onde falhas na detecção podem ter consequências críticas.

1.3. Importância do Problema

A relevância desta pesquisa fundamenta-se em múltiplos aspectos:

- **Segurança Crítica:** Pelotões veiculares operam em alta velocidade com distâncias reduzidas entre veículos, tornando qualquer falha de comunicação ou ataque cibernético potencialmente catastrófico.
- **Eficiência dos Sistemas:** Ataques FDI não detectados podem degradar significativamente a eficiência do pelotão, resultando em maior consumo de combustível, congestionamentos e instabilidade no fluxo de tráfego.
- **Lacuna nas Soluções Existentes:** Métodos tradicionais de segurança frequentemente introduzem overhead computacional e de comunicação significativo, impactando negativamente o desempenho do sistema.
- **Escalabilidade:** Com a crescente adoção de veículos autônomos, a necessidade de soluções robustas e eficientes para detecção de ataques torna-se cada vez mais urgente.

2. Objetivos

2.1. Objetivo Geral

Explorar e avaliar abordagens avançadas para a **detecção de ataques de False Data Injection em pelotões veiculares**, a partir do trabalho já realizado para a disciplina de Redes Sem Fio, com foco em três frentes principais:

- Otimização de hiperparâmetros em algoritmos de Reinforcement Learning;
- Desenvolvimento de cenários de tráfego mais realistas para treinamento e validação;
- Comparação de algoritmos alternativos ao RL.

2.2. Objetivos Específicos

2.2.1. POC I – Primeiro Semestre (Exploratório)

- Realizar revisão sistemática do estado da arte em detecção de ataques em redes veiculares;
- Investigar o impacto da otimização de hiperparâmetros em algoritmos de RL;
- Criar protótipos de cenários de tráfego mais realistas para avaliação preliminar;
- Comparar de forma inicial algoritmos alternativos ao RL (ex.: métodos supervisionados, ensembles, deep learning);
- Selecionar 2–3 abordagens mais promissoras para desenvolvimento completo no POC II;
- *Extras, se houver tempo:* explorar treinamento online vs. offline; avaliar requisitos para comunicação 6G; analisar extensão para outros tipos de ataques além de FDI.

2.2.2. POC II – Segundo Semestre (Execução)

- Implementar de forma robusta as abordagens selecionadas no POC I;
- Conduzir avaliações sistemáticas em cenários diversos, utilizando métricas de acurácia, sensibilidade, especificidade e estabilidade do pelotão;
- Validar experimentalmente a efetividade das soluções propostas;
- Consolidar os resultados em artigo científico e documentação final do projeto.

3. Referencial Teórico

3.1. Redes Veiculares (VANETs)

VANETs (Vehicular Ad Hoc Networks) são redes de comunicação sem fio formadas por veículos equipados com dispositivos que permitem comunicação vehicle-to-vehicle (V2V) e vehicle-to-infrastructure (V2I). Caracterizam-se por alta mobilidade dos nós e topologia dinâmica.

O funcionamento baseia-se na transmissão periódica de mensagens *beacon* contendo informações críticas como posição GPS, velocidade instantânea, aceleração e direção. Essas informações são processadas pelos sistemas embarcados para aplicações de segurança ativa, controle de tráfego e coordenação entre veículos.

3.2. Pelotões Veiculares

Pelotões veiculares são formações cooperativas onde múltiplos veículos se movem em comboio mantendo distâncias reduzidas através de controle automatizado. A coordenação é viabilizada pela comunicação contínua entre os membros do pelotão, permitindo sincronização precisa de movimentos.

A arquitetura típica segue um modelo hierárquico: o veículo líder define a trajetória e perfil de velocidade, enquanto os seguidores ajustam seu comportamento com base nas informações recebidas via mensagens *beacon*. O controle requer algoritmos que processem dados de telemetria em tempo real, mantendo estabilidade mesmo sob condições dinâmicas.

Os benefícios incluem:

- Redução significativa do consumo energético (aproveitamento aerodinâmico);
- Aumento da capacidade das vias (distâncias menores);
- Melhoria da segurança através da coordenação automatizada que elimina fatores humanos de erro.

3.3. Ataques de False Data Injection (FDI)

Ataques FDI representam uma vulnerabilidade crítica em sistemas veiculares conectados, consistindo na inserção maliciosa de dados falsos nas comunicações entre veículos. O atacante intercepta e modifica mensagens *beacon*, comprometendo a integridade das informações utilizadas para tomada de decisões.

Em pelotões veiculares, esses ataques manifestam-se através da manipulação de parâmetros críticos:

- **Falsificação de velocidade:** alteração dos valores reportados, induzindo comportamentos inadequados nos seguidores;
- **Manipulação de aceleração:** inserção de valores extremos (ex.: $-12\,m/s^2$) simulando frenagens de emergência;
- **Distorção de posição:** modificação de coordenadas GPS criando percepção incorreta da localização.

As consequências podem ser severas: propagação de frenagens em cascata, desestabilização da formação do pelotão, degradação da eficiência energética e, em casos extremos, risco de colisões. A detecção eficaz desses ataques é fundamental para a operação segura de sistemas veiculares autônomos.

3.4. Trabalhos Relacionados

A aplicação de técnicas de aprendizado de máquina em sistemas veiculares autônomos e a necessidade de abordar questões de segurança cibernética em pelotões têm motivado diversos estudos na literatura.

[Prathiba et al. 2021] propõem abordagens híbridas combinando Deep Reinforcement Learning com Algoritmos Genéticos para formação de pelotões, utilizando a mesma *stack* de simulação deste trabalho (PLEXE, SUMO, OMNeT++), mas focando na otimização da formação sem abordar aspectos de segurança cibernética. Os autores identificam que o DRL apresenta convergência lenta, utilizando algoritmos genéticos para acelerar este processo.

[Vyas and Dey 2024] exploram Reinforcement Learning de forma adversarial para gerar ataques em pelotões, desenvolvendo agentes que causam distúrbios furtivos no comportamento do pelotão. Contrariamente ao foco deste estudo, que utiliza RL como defesa para detectar ataques, a pesquisa de Vyas e Dey concentra-se na geração inteligente destes.

[Taylor et al. 2023] apresentam revisão abrangente sobre comunicação em pelotões veiculares, destacando a arquitetura, as principais ameaças de segurança e os desafios em aberto. Esse trabalho reforça a necessidade de mecanismos de detecção mais eficientes para lidar com ataques sofisticados como os de False Data Injection.

É importante destacar que os trabalhos aqui apresentados fazem parte de uma exploração inicial do estado da arte. Conforme previsto na metodologia, esta revisão será aprofundada ao longo do desenvolvimento do projeto, com o objetivo de consolidar o conhecimento sobre as soluções existentes e direcionar de forma mais precisa o avanço da pesquisa proposta.

3.5. Posicionamento da Proposta

A revisão da literatura revela uma lacuna importante: as soluções existentes para detecção de ataques em pelotões veiculares frequentemente introduzem *overhead* significativo na rede, seja através de sistemas de autenticação adicionais, protocolos criptográficos complexos ou mecanismos de verificação que demandam recursos computacionais e de comunicação extras.

Este trabalho diferencia-se ao propor detecção "gratuita" de ataques FDI — uma abordagem baseada em Reinforcement Learning que realiza detecção intrínseca utilizando apenas os dados de comunicação já existentes no pelotão, sem necessidade de infraestrutura adicional complexa ou protocolos que impactem negativamente a performance do sistema.

A proposta investiga três frentes para otimizar essa detecção:

- Refinamento de hiperparâmetros;
- Desenvolvimento de cenários de simulação realistas;
- Comparação entre paradigmas de aprendizado.

O objetivo é superar as limitações identificadas no trabalho anterior, desenvolvido no último semestre (acurácia de 52,6% e especificidade de 35,6%), e contribuir para soluções práticas de segurança em pelotões veiculares.

4. Metodologia

4.1. Abordagem Geral

A metodologia proposta segue uma estratégia exploratória-investigativa dividida em dois semestres, partindo do trabalho já desenvolvido na disciplina de Redes Sem Fio como *baseline*. O projeto será conduzido através de investigação sistemática de múltiplas frentes de pesquisa, sempre norteada por três questões fundamentais:

- **O que é factível?** Avaliação das limitações técnicas e recursos disponíveis;
- **O que ainda não foi feito?** Identificação de lacunas no estado da arte;
- **O que tem aplicabilidade real?** Foco em soluções com potencial prático.

4.2. POC I - Primeiro Semestre: Fase Exploratória

4.2.1. Revisão Sistemática do Estado da Arte

- Mapeamento abrangente da literatura em detecção de ataques cibernéticos em redes veiculares;
- Análise crítica das metodologias existentes, identificando vantagens, limitações e lacunas;
- Identificação de oportunidades de pesquisa não exploradas adequadamente.

4.2.2. Investigação de Múltiplas Frentes

O trabalho explorará sistematicamente as seguintes abordagens:

Otimização de Hiperparâmetros em RL:

- Refinamento dos parâmetros do modelo PPO existente (learning rate, batch size, policy network architecture);
- Investigação de outros algoritmos de RL (A3C, SAC, TD3) para comparação de performance;
- Análise de sensibilidade para identificar parâmetros mais impactantes na detecção.

Cenários de Treinamento Mais Realistas:

- Desenvolvimento de configurações de tráfego diversificadas (densidade variável, condições meteorológicas);
- Implementação de padrões de movimento mais complexos e realistas no simulador Plexe;
- Avaliação do impacto de diferentes topologias de rede na eficácia da detecção.

Comparação com Algoritmos Alternativos:

- Avaliação de estratégias alternativas de detecção de anomalias.
- Exploração de técnicas de aprendizado supervisionado, não supervisionado e híbridas;

Investigações Complementares (se houver tempo):

- Análise de viabilidade para implementação em redes 6G;
- Estudo de extensão para outros tipos de ataques;
- Avaliação de treinamento online versus offline (o trabalho inicial foi feito com treinamento offline).

4.2.3. Refinamento dos Resultados Existentes

- Análise detalhada das limitações identificadas no trabalho anterior;
- Implementação de melhorias incrementais no *dataset* e pré-processamento;
- Validação cruzada mais robusta dos modelos existentes.

4.2.4. Entrega do Relatório Final do POC I

- Consolidação dos resultados obtidos durante a fase exploratória;
- Descrição detalhada das abordagens investigadas e suas respectivas análises;
- Documentação das limitações identificadas e oportunidades de melhoria para o POC II;
- Inclusão de gráficos, tabelas e métricas que evidenciem os achados preliminares;

4.3. POC II - Segundo Semestre: Fase de Implementação

4.3.1. Definição do Escopo Final

- Seleção das 2-3 abordagens mais promissoras identificadas no POC I;
- Estabelecimento de critérios de avaliação e métricas de performance;
- Definição do protocolo experimental para validação rigorosa.

4.3.2. Implementação Robusta

- Desenvolvimento completo das metodologias selecionadas;

4.3.3. Validação Experimental

- Execução de experimentos em cenários diversos e controlados;
- Análise estatística dos resultados obtidos;
- Comparação quantitativa entre diferentes abordagens e com o *baseline*.

4.3.4. Análise e Documentação

- Interpretação crítica dos resultados experimentais;
- Identificação de limitações e direções futuras;
- Preparação de artigo científico para submissão;
- Elaboração do relatório final do projeto.

4.4. Uso de Ferramentas de Inteligência Artificial

Este projeto utiliza ferramentas de IA como suporte metodológico em atividades específicas:

1. Documentação automatizada de código-fonte complexo utilizando Claude CLI (+650 linhas), conforme aplicado no trabalho anterior para análise do framework Veins;

2. Assistência na estruturação e revisão de documentos acadêmicos;
3. Suporte na análise preliminar de literatura.

O desenvolvimento conceitual, implementação de algoritmos, análise de resultados e conclusões são de autoria própria do pesquisador.

5. Resultados Esperados

Ao final do projeto, espera-se a produção de um artigo científico completo, contendo resultados robustos e consistentes com as etapas de investigação e desenvolvimento realizadas.

Além disso, objetiva-se o aprimoramento das competências do pesquisador no processo de pesquisa acadêmica, incluindo a comunicação eficaz com o orientador, a aplicação prática dos conhecimentos adquiridos ao longo do curso, e principalmente a demonstração de habilidades metodológicas, analíticas e de desenvolvimento técnico consolidadas durante a formação.

Espera-se também que os resultados do projeto contribuam para a melhoria da detecção de ataques em pelotões veiculares, oferecendo conhecimento aplicável em sistemas veiculares autônomos e reforçando o impacto prático e científico da pesquisa.

6. Etapas e Cronograma

Semana	Período	Atividades Previstas
1	01/09 - 07/09	Desenvolvimento da Proposta
2-3	08/09 - 14/09	Revisão do Estado da Arte
	15/09 - 21/09	
4-5	22/09 - 28/09	Exploração de Otimização dos Resultados de RL
	29/09 - 05/10	
6-7	06/10 - 12/10	Exploração de Cenários de Treinamento Mais Realistas
	13/10 - 19/10	
8	20/10 - 26/10	Preparação do Pitch do Vídeo
9-10	27/10 - 02/11	Exploração de Comparação com Algoritmos Alternativos
	03/11 - 09/11	
11	10/11 - 16/11	Exploração das Investigações Complementares
12	17/11 - 23/11	Desenvolvimento do Pôster
13	24/11 - 28/11	Desenvolvimento do Pôster e do Relatório Final
14+	29/11 - 07/12	Desenvolvimento do Relatório Final

Table 1. Cronograma previsto para realização das atividades do projeto (semanas preparatórias para entregas destacadas em amarelo).

References

Prathiba, S. B., Raja, G., Dev, K., Kumar, N., and Guizani, M. (2021). A hybrid deep reinforcement learning for autonomous vehicles smart-platooning. *IEEE Transactions on Vehicular Technology*, 70(12):13340–13350.

Taylor, S., Ahmad, F., Nguyen, H., and Shaikh, S. (2023). Vehicular platoon communication: Architecture, security threats and open challenges. *Sensors*, 23(1):134.

Vyas, S. D. and Dey, S. (2024). Reinforcement learning-based adversarial attack generation examples in connected and autonomous vehicles: A case study on vehicular platoons. *IFAC-PapersOnLine*, 58(28):78–83.