DETECÇÃO DE ATAQUES DE FALSE DATA INJECTION EM PELOTÕES VEICULARES USANDO REINFORCEMENT LEARNING

César de Paula Morais, Orientador Dr. Luiz Filipe Menezes Vieira

Departamento de Ciência da Computação, Universidade Federal de Minas Gerais (UFMG), Belo Horizonte, Brasil

cesar.morais@dcc.ufmg.br

INTRODUÇÃO

A adoção de **veículos conectados e autônomos**, especialmente em **formações de pelotão**, tem se tornado uma tendência central nos sistemas de transporte inteligente. No entanto, essa dependência de comunicação entre veículos abre espaço para vulnerabilidades cibernéticas.

Este projeto investiga a **detecção de False Data Injection (FDI)**, ataques em que um agente malicioso insere dados falsos sobre velocidade, aceleração ou posição, usando **Reinforcement Learning.**

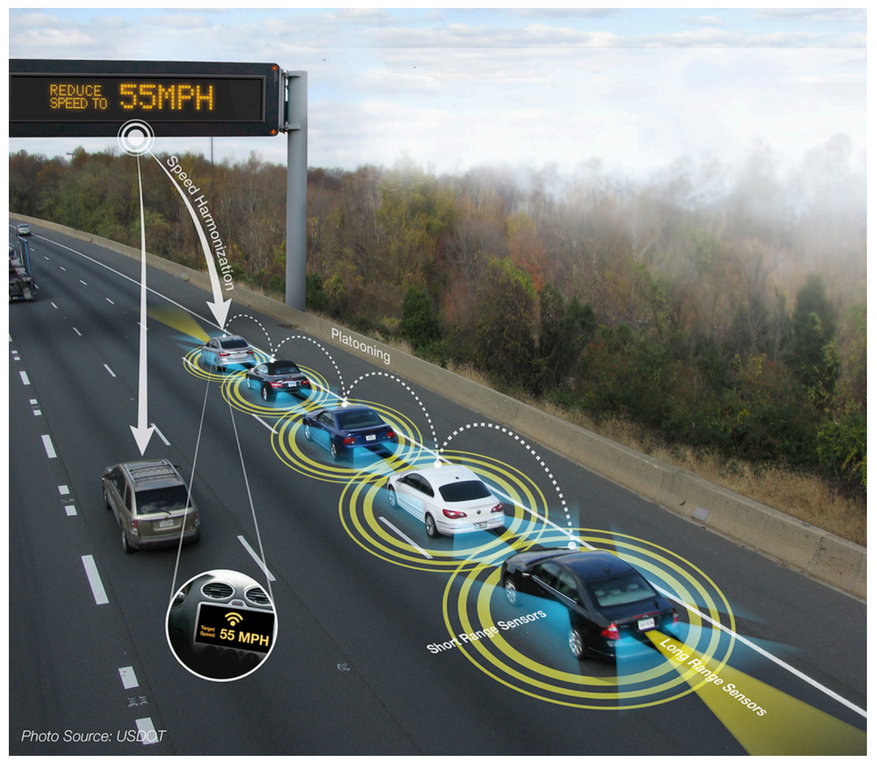


Figura 1: Exemplo de caso de uso de pelotões veiculares.

BENEFÍCIOS

Economia de combustível

Maior segurança

Redução de Emissões

RISCOS DO ATAQUE FDI

Frenagem brusca

Disrupção da formação

Colisões inter-pelotão

RESULTADOS JÁ ALCANÇADOS

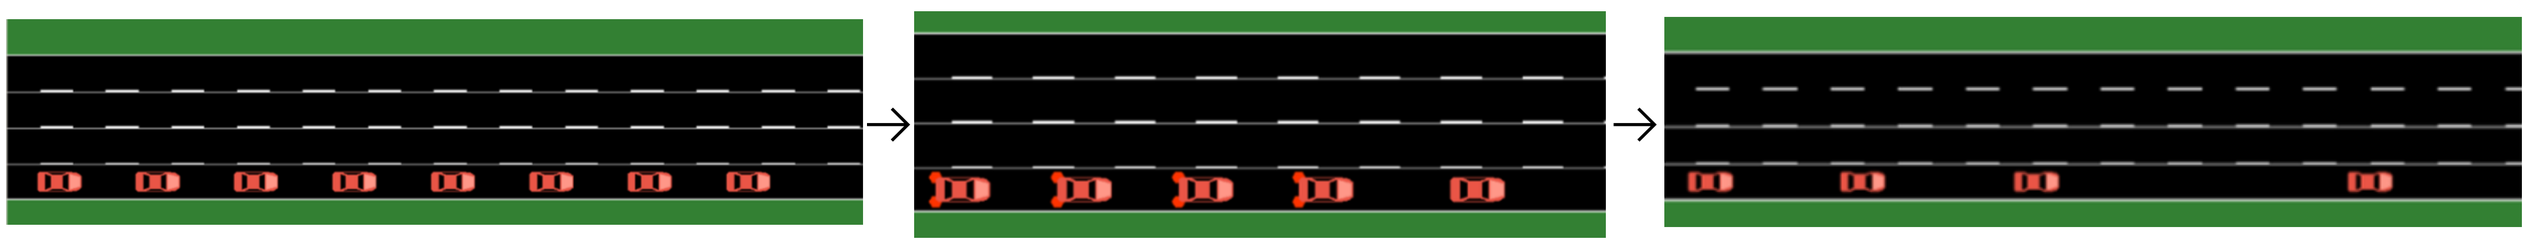


Figura 2: Evolução do ataque FDI ao longo do tempo. Simulação via simulador Plexe.

- Modificação do simulador **Plexe** para i**nclusão do ataque FDI** em um cenário de frenagem em linha reta (Fig. 2).
- **Geração de um dataset** com ~10k amostras balanceadas (ataque/não ataque).
- Treinamento do modelo de **Reinforcement Learning PPO** offline usando a biblioteca Stable Baselines3.
- **Busca e ajuste de hiperparâmetros** para melhoria do desempenho.
- Resultados promissores (Fig. 3), com **boa taxa de detecção de ataques** e margem para otimização.

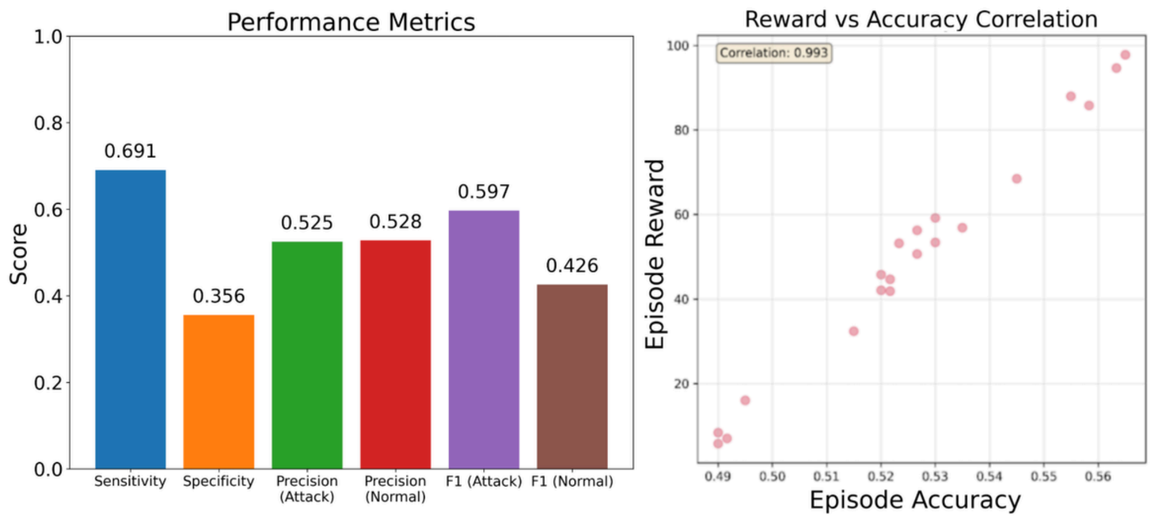


Figura 3: Resultados obtidos pelo modelo PPO. Observa-se um melhor desempenho na identificação de falsos positivos (sensitivity) em comparação aos falsos negativos (specificity). Nota-se também indícios de uma boa modelagem, refletida pelo aumento consistente de reward e accuracy.

FRENTES EXPLORADAS NO POC 1

Revisão do Estado da Arte

- Leitura sobre detecção de ataques em redes veiculares.
- Avaliação crítica das principais metodologias e suas limitações.
- Identificação de lacunas que motivam novas abordagens.

Otimização do uso de RL

- Testes de hiperparâmetros e ajustes de política no PPO.
- Reformulação da recompensa para impedir detecções conservadoras.
- Exploração preliminar de alternativas em RL.

Melhoria no cenário de treinamento

- Avaliação do impacto de novos cenários sobre o modelo.
- Observação preliminar de como pequenas variações no comportamento do pelotão afetariam o modelo.

Comparação com algoritmos alternativos

- Avaliação de estratégias alternativas de detecção de anomalias.
- Exploração de técnicas de aprendizado supervisionado, não supervisionado e híbridas;

DCC DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO

UFMG