Exploração da Detecção de Ataques de False Data Injection (FDI) em Pelotões Veiculares usando Reinforcement Learning

César de Paula Morais
Departamento de Ciência da Computação
Universidade Federal de Minas Gerais
Belo Horizonte, Brasil
cesarmorais@dcc.ufmg.br

Dr. Luiz Filipe Menezes Vieira
Departamento de Ciência da Computação
Universidade Federal de Minas Gerais
Belo Horizonte, Brasil
lfvieira@dcc.ufmg.br

***Abstract*—Ataques de *False Data Injection* (FDI) representam uma ameaça significativa à segurança e à estabilidade de pelotões veiculares conectados, nos quais a coordenação cooperativa depende da integridade das informações trocadas entre os veículos. Este trabalho investiga a aplicação de *Reinforcement Learning* (RL), em particular do algoritmo Proximal Policy Optimization (PPO), para a detecção em tempo real de ataques FDI em ambiente simulado. Foram avaliadas tanto uma formulação básica de função de recompensa quanto extensões temporais projetadas para incorporar consequências de longo prazo nas decisões do agente. Os resultados experimentais mostraram que, apesar da diversidade de configurações exploradas, o modelo convergiu de forma consistente para comportamento conservador, apresentando desempenho discriminativo limitado (acurácia de 52,6% e especificidade de 35,6%). Esses achados indicam que a formulação atual do ambiente e da função de recompensa ainda não é suficiente para produzir detectores competitivos, apesar de o trabalho ter cumprido seu objetivo principal, de ser uma fase exploratória. Tal fase exploratória fornece um diagnóstico claro das limitações fundamentais e orienta as direções metodológicas a serem investigadas na POC 2, incluindo a avaliação de algoritmos alternativos de RL, baselines supervisionados e não supervisionados, e cenários de treinamento mais realistas.**

***Index Terms*—Detecção de anomalias, Veículos conectados e automatizados, False Data Injection, Reinforcement Learning, Redes veiculares, PPO.**

I. INTRODUÇÃO

Com o crescimento acelerado das cidades e a busca por soluções sustentáveis para a mobilidade urbana, os sistemas de transporte inteligente emergem como área crucial para o futuro da infraestrutura viária. Entre as aplicações mais promissoras destacam-se os pelotões veiculares – formações cooperativas onde múltiplos veículos se deslocam de forma coordenada, mantendo distâncias reduzidas através de controle automatizado e comunicação contínua. Esses sistemas oferecem benefícios substanciais documentados na literatura: potencial de redução de até 90% dos acidentes, economias anuais estimadas em $190 bilhões, diminuição significativa do consumo energético através do aproveitamento aerodinâmico, e aumento da capacidade das vias devido ao espaçamento otimizado entre veículos [1]. Contudo, a concretização desses benefícios depende criticamente da segurança cibernética: a natureza cooperativa dos pelotões, fundamentada na troca contínua de informações via mensagens beacon contendo dados de posição, velocidade e aceleração, introduz vulnerabilidades que podem comprometer tanto a eficiência operacional quanto a segurança dos ocupantes [2].

Dentre as ameaças cibernéticas a pelotões veiculares, os ataques de *False Data Injection* (FDI) representam uma classe particularmente crítica. Nesses ataques, adversários interceptam e manipulam mensagens beacon, injetando dados falsos sobre parâmetros operacionais – como acelerações extremas simulando frenagens de emergência, velocidades adulteradas ou coordenadas GPS distorcidas – que induzem comportamentos inadequados nos veículos seguidores. Tais manipulações podem desencadear frenagens bruscas desnecessárias, acelerações perigosas ou perda de coordenação do pelotão, potencialmente resultando em colisões e comprometimento da estabilidade cooperativa do sistema. As abordagens tradicionais de detecção – baseadas em verificações criptográficas, sistemas de autenticação adicionais ou validação por infraestrutura externa (*Road-Side Units*) – frequentemente introduzem *overhead* significativo em termos de latência de comunicação, processamento computacional e custos operacionais, limitando sua viabilidade prática em cenários de operação em tempo real com restrições de recursos.

Neste trabalho, investigamos uma abordagem alternativa baseada em *Reinforcement Learning* (RL) para detecção intrínseca de ataques FDI em pelotões veiculares, utilizando exclusivamente os dados de comunicação já disponíveis no sistema sem necessidade de infraestrutura adicional. Especificamente, desenvolvemos e avaliamos agentes baseados no algoritmo *Proximal Policy Optimization* (PPO) treinados para distinguir autonomamente entre comportamentos legítimos e maliciosos através da análise de padrões temporais e estatísticos nas mensagens beacon. Nossas principais contribuições são: **(i)** formulação e avaliação sistemática de funções de recompensa temporais que incorporam consequências de longo prazo das decisões de detecção, considerando impactos na estabilidade da formação veicular; **(ii)** exploração abrangente do espaço de hiperparâmetros do PPO através de busca sistemática em ambiente acelerado por GPU, totalizando aproximadamente 25.920 configurações candidatas; **(iii)** análise crítica das limitações fundamentais da abordagem baseada em RL para este problema específico, identificando que o comportamento conservador persistente (acurácia de 52,6%, especificidade de 35,6%) decorre primariamente da ausência de sinal de aprendizado progressivo nas curvas de recompensa; e **(iv)** revisão sistemática do estado da arte estruturada em quatro eixos temáticos complementares, posicionando esta pesquisa como a primeira a aplicar PPO para detecção de FDI em pelotões veiculares e estabelecendo *benchmarks* prioritários para comparação futura com métodos supervisionados, não-supervisionados e algoritmos alternativos de RL (DQN, A2C).

Diferentemente de trabalhos anteriores que focam em VANETs gerais [3], [4], proteção de barramento CAN [5], ou detecção baseada em observadores de estado com dependência de modelos matemáticos completos [6], nossa abordagem opera de forma distribuída em cada veículo do pelotão, aprende políticas de detecção adaptativas através de interação com o ambiente simulado, e não requer conhecimento prévio dos parâmetros de controle de outros veículos ou infraestrutura de nuvem [7]. Embora os resultados desta fase exploratória (POC 1) revelem limitações significativas que motivam investigação futura, o trabalho cumpre seu objetivo de mapear sistematicamente os desafios fundamentais, diagnosticar causas do comportamento sub-ótimo observado, e estabelecer direções metodológicas claras para avanços subsequentes.

O restante deste trabalho está organizado da seguinte forma. A Seção II detalha a metodologia de pesquisa exploratória-investigativa adotada, incluindo desafios técnicos do ambiente de simulação Plexe e estratégias de geração do dataset balanceado. A Seção III descreve a arquitetura do sistema de treinamento *offline*, o ambiente customizado baseado em Gymnasium, e a seleção do algoritmo PPO. A Seção IV apresenta revisão sistemática da literatura em quatro eixos: visão geral de pelotões veiculares, abordagens com RL para cibersegurança, outros usos de RL em pelotões, e detecção específica de ataques FDI. A Seção V investiga a otimização de hiperparâmetros e o desenvolvimento de funções de recompensa temporais incorporando análise de formação veicular. A Seção VI examina oportunidades de expansão para cenários de treinamento mais realistas, incluindo diversificação de topologias de comunicação e modelos de ataque sofisticados. A Seção VII posiciona este trabalho em relação ao estado da arte e identifica *benchmarks* prioritários para validação futura. A Seção VIII consolida os resultados obtidos, analisando tanto configurações com recompensa simples quanto temporal. A Seção IX delineia as direções previstas para a POC 2, focando em análise aprofundada das causas do comportamento sub-ótimo e comparação sistemática com métodos alternativos. Finalmente, a Seção X sintetiza as contribuições desta fase exploratória e estabelece o caminho para evolução rumo a soluções com desempenho compatível com aplicações práticas.

II. METODOLOGIA

A. *Abordagem Geral da Pesquisa*

Este trabalho adota uma abordagem exploratória-investigativa, característica fundamental da fase de POC 1. O objetivo primário não é a otimização imediata de resultados, mas sim a expansão do entendimentos. Esta fase exploratória estabelece as bases conceituais e técnicas necessárias para a expansão aprofundada prevista no POC 2, onde as abordagens mais promissoras identificadas serão desenvolvidas de forma robusta e sistemática.

O trabalho preliminar desenvolvido na disciplina de Redes Sem Fio estabeleceu um *baseline* inicial para a pesquisa, gerando resultados que, embora revelem limitações significativas para aplicações práticas, demonstram a viabilidade conceitual da abordagem. Estes resultados iniciais são apresentados detalhadamente na Seção VIII e servem como ponto de partida para as investigações conduzidas neste projeto.

B. *Ambiente de Desenvolvimento e Desafios Técnicos*

O ambiente de simulação utilizado baseou-se na plataforma Plexe, um framework especializado para sistemas de pelotões veiculares que integra os simuladores SUMO (*Simulation of Urban Mobility*) para modelagem de tráfego e OMNeT++ para simulação de redes de comunicação. O Plexe estende as funcionalidades do Veins (*Vehicles in Network Simulation*), proporcionando capacidades específicas para simulação de comportamentos cooperativos em pelotões, incluindo modelos de controle longitudinal e lateral dos veículos.

Para acelerar o processo de configuração do ambiente experimental, optou-se pela utilização da máquina virtual Instant Plexe 3.0, que fornece uma instalação pré-configurada com todas as dependências necessárias (OMNeT++, SUMO, Veins e Plexe) em versões compatíveis. Esta abordagem eliminou potenciais conflitos de versionamento e reduziu significativamente o tempo de *setup* inicial.

Contudo, a utilização do ambiente virtualizado apresentou limitações técnicas significativas que impactaram o desenvolvimento da pesquisa. As restrições de recursos computacionais, particularmente em termos de memória virtual alocada, resultaram em limitações de performance durante simulações mais complexas. Adicionalmente, o sistema operacional base da máquina virtual (Debian 10) apresentou incompatibilidades com algumas bibliotecas mais recentes necessárias para implementações específicas, demandando adaptações substanciais no código e nas dependências utilizadas.

Estes fatores técnicos influenciaram diretamente as decisões de treinamento adotadas – discutidas em detalhes na Seção III – e representaram um dos principais desafios metodológicos desta pesquisa. A necessidade de contornar as limitações do ambiente virtualizado exigiu o desenvolvimento de soluções alternativas que, embora tenham mantido a viabilidade da pesquisa, impuseram restrições ao escopo das experimentações realizadas nesta fase exploratória.

C. Documentação Assistida por Inteligência Artificial

A implementação de ataques FDI no ambiente de simulação representou um desafio técnico significativo, exigindo modificações substanciais no código-fonte do framework Plexe. A análise inicial do código-fonte revelou elevada complexidade arquitetural e documentação limitada, fatores que representaram obstáculos consideráveis para a compreensão e modificação do sistema.

Para superar essas limitações, desenvolveu-se uma estratégia sistemática de documentação assistida por *Large Language Models* (LLMs), especificamente utilizando o Claude CLI para análise e documentação automatizada do código-fonte do Veins. Este processo resultou na geração de mais de 650 linhas de documentação técnica, proporcionando uma base sólida para o planejamento das modificações necessárias.

A documentação gerada permitiu não apenas uma compreensão aprofundada dos mecanismos internos do simulador, mas também a elaboração de estratégias eficientes para as implementações subsequentes. Esta abordagem metodológica demonstrou-se fundamental para acelerar o processo de desenvolvimento e garantir a precisão das modificações implementadas no ambiente de simulação. É importante ressaltar que, embora ferramentas de IA tenham sido utilizadas como suporte para documentação e estruturação de código complexo, o desenvolvimento conceitual, a implementação de algoritmos, a análise de resultados e as conclusões são de autoria própria do pesquisador.

D. Implementação de Ataques FDI e Geração do Dataset

1) Modelagem do Cenário de Ataque: A implementação do ataque FDI foi realizada através da manipulação das mensagens beacon do protocolo de comunicação padrão do Plexe. Os beacons constituem mensagens periódicas de controle que cada veículo transmite aos nós vizinhos, contendo informações críticas sobre seu estado operacional, incluindo posição, velocidade, aceleração e direção.

O cenário de ataque desenvolvido consistiu em um pelotão de veículos se deslocando em trajetória retilínea com velocidade controlada pelo veículo líder. Em instantes aleatórios da simulação, o veículo líder (comprometido pelo atacante) injeta dados falsos nas mensagens beacon transmitidas aos seguidores. Especificamente, o veículo comprometido transmite uma mensagem beacon modificada contendo um valor de desaceleração anormalmente elevado (-12 m/s^2), simulando uma condição de frenagem de emergência que não corresponde ao comportamento real do veículo.

Esta manipulação induz o veículo seguinte a interpretar erroneamente o estado do líder, resultando em uma resposta de frenagem abrupta. Os resultados da simulação demonstraram a propagação do comportamento malicioso através do pelotão, caracterizada por frenagens em cascata nos veículos subsequentes. Embora não tenham sido registradas colisões durante esta implementação inicial, observou-se degradação significativa na estabilidade do pelotão e na eficiência do fluxo de tráfego.

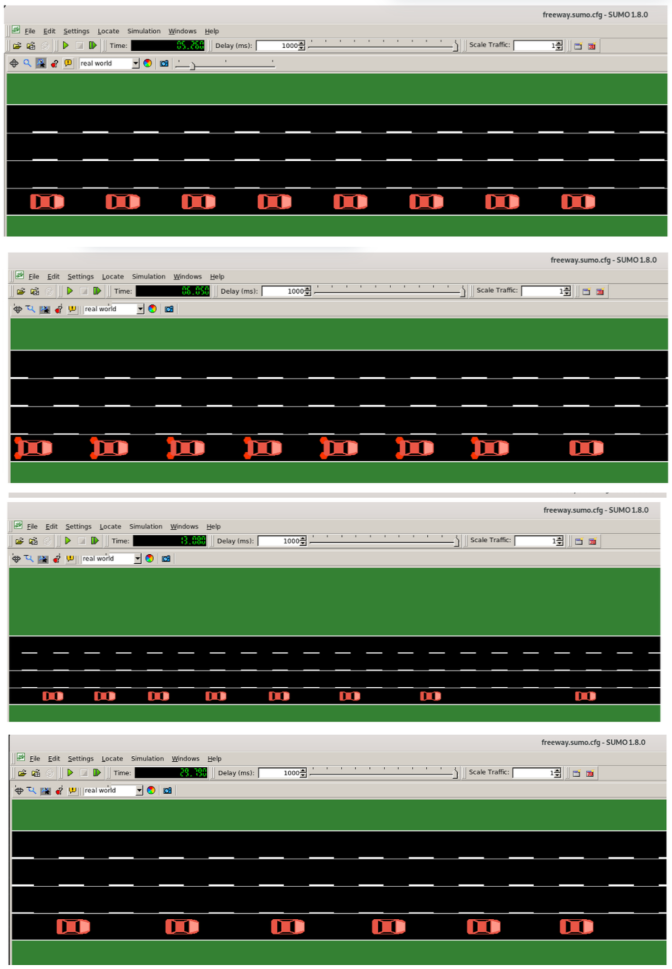
freeway.sumo.cfg - SUMO 1.8.0
File Edit Settings Locate Simulation Windows Help
Time:
Delay (ms):
1000
Scale Traffic:
real world

Fig. 1. Evolução do ataque de injeção de dados falsos ao longo do tempo: (1) pelotão estabilizado antes do ataque; (2) início do ataque aos 5 segundos; (3) maior distância média entre os veículos aos 15 segundos; (4) reestabilização parcial do pelotão aos 30 segundos.

2) Estratégia de Geração do Dataset: Para a geração do dataset de treinamento e validação, adotou-se uma abordagem balanceada visando garantir representatividade adequada de ambas as classes (comunicações normais e ataques FDI). Foram executadas múltiplas simulações com diferentes configurações de probabilidade de ataque, totalizando aproximadamente 35.000 registros brutos.

A estratégia de geração consistiu em três tipos de simulações:

- **Cenário de controle**: aproximadamente 10.000 registros sem qualquer ocorrência de ataque, representando a operação normal do pelotão;
- **Cenário misto**: aproximadamente 15.000 registros gerados com probabilidade de 30% de ocorrência de ataque em cada timestep da simulação;
- **Cenário de ataque**: aproximadamente 10.000 registros com ataques em instantes conhecidos e controlados.

Ao final do processo de geração, todos os cenários foram combinados e submetidos a um processo de filtragem para remoção de registros inconsistentes ou duplicados, resultando em um dataset final de aproximadamente 9.000 observações. Cada registro representa um evento de transmissão de beacon, caracterizado por atributos temporais, comportamentais e contextuais extraídos da simulação.

O dataset resultante contém 15 variáveis por observação, distribuídas em diferentes categorias: informações temporais; identificação; dinâmicas de aceleração; indicadores de ataque; dados de mobilidade; medidas estatísticas e metadados.

A variável-alvo binária `is_attack` distingue entre comunicações legítimas (valor 0) e instâncias de ataque FDI (valor 1). As instâncias de ataque são caracterizadas por desvios significativos nos valores de aceleração, com acelerações injetadas atingindo magnitudes de aproximadamente -12.0 m/s^2, representando cenários de frenagem de emergência. Em contraste, a operação normal apresenta valores próximos de zero, refletindo um comportamento de pelotão estável. A variável `acceleration_change` captura a magnitude da injeção de dados, oferecendo uma medida direta da intensidade do ataque.

Este dataset balanceado e detalhadamente anotado constitui a base para todas as experimentações conduzidas neste trabalho, permitindo a exploração de diferentes abordagens de aprendizado de máquina para detecção de ataques FDI.

III. DETALHES DO TREINAMENTO

A. Arquitetura do Sistema de Treinamento

Devido às limitações técnicas identificadas com a integração do VeinsGym, optou-se por uma abordagem alternativa que utiliza os dados pré-gerados das simulações Plexe para treinamento offline. Esta estratégia mantém a eficácia do aprendizado por reforço enquanto elimina a dependência de simulações em tempo real e os problemas de overhead computacional associados.

A arquitetura final implementada consiste em um pipeline de dados simplificado: *Simulações Plexe* $\rightarrow$ *Arquivos CSV* $\rightarrow$ *Ambiente Customizado* $\rightarrow$ *Agente PPO*. Este fluxo permite o treinamento robusto do agente detector sem as complexidades da integração direta com o simulador.

B. Ambiente de Treinamento Customizado

Foi desenvolvido um ambiente customizado denominado `FDIDetectionEnvOffline`, implementado utilizando o framework Gymnasium, que substitui a funcionalidade do VeinsGym. Este ambiente opera através da reprodução (*replay*) dos dados históricos de simulação, permitindo que o agente experimente cenários de ataque e não-ataque de forma controlada.

O ambiente processa um espaço de observação de 8 dimensões, extraindo características relevantes dos dados de aceleração e suas derivadas estatísticas. Especificamente, as features incluem: aceleração original, aceleração injetada, mudança de aceleração, valor absoluto da aceleração, média da aceleração, desvio padrão da aceleração, tendência da aceleração e tempo desde o início da simulação. Esta seleção de características foi baseada em análise exploratória preliminar que identificou estes atributos como os mais discriminativos para detecção de ataques FDI.

A cada episódio, o ambiente amostra aleatoriamente registros do dataset pré-gerado, simulando a experiência sequencial de detecção de ataques FDI em redes veiculares. Cada episódio possui duração máxima de 600 timesteps, proporcionando ao agente experiência suficiente para aprender padrões de comportamento normal e malicioso. O ambiente retorna recompensas baseadas na precisão das classificações do agente, incentivando tanto a detecção correta de ataques quanto a minimização de falsos positivos – aspecto crítico para aplicações práticas onde alarmes falsos excessivos comprometem a confiabilidade do sistema.

C. Algoritmo de Aprendizado

O algoritmo selecionado foi o *Proximal Policy Optimization* (PPO) da biblioteca Stable-Baselines3, reconhecido por sua estabilidade e eficiência em problemas de classificação binária. O PPO utiliza uma política *Multi-Layer Perceptron* (MLP) para processar as características extraídas dos dados de comunicação veicular.

A escolha do PPO fundamenta-se em suas características técnicas particularmente adequadas para este problema: (i) estabilidade no treinamento através do mecanismo de clipping que limita atualizações de política; (ii) eficiência amostral superior a algoritmos policy gradient tradicionais; e (iii) robustez a variações de hiperparâmetros, facilitando experimentação inicial. Adicionalmente, o PPO demonstrou desempenho competitivo em diversos benchmarks de aprendizado por reforço, tornando-o uma escolha conservadora e confiável para esta fase exploratória.

IV. REVISÃO DO ESTADO DA ARTE

Esta seção apresenta uma revisão sistemática da literatura relevante para detecção de ataques FDI em pelotões veiculares utilizando técnicas de aprendizado de máquina. A revisão foi estruturada em quatro eixos temáticos complementares que, em conjunto, fornecem a fundamentação teórica necessária para o desenvolvimento deste trabalho.

A. Visão Geral de Pelotões Veiculares

A literatura sobre pelotões veiculares estabelece um conjunto robusto de fundamentos técnicos e operacionais que contextualizam os desafios de segurança investigados neste trabalho.

O estudo apresentado em Taylor et al. (2023) [2] realiza uma revisão abrangente sobre comunicação em pelotões veiculares, destacando a arquitetura de comunicação, as principais ameaças de segurança e os desafios em aberto. Os autores sistematizam as vulnerabilidades inerentes à dependência de comunicações inter-veiculares, enfatizando que a natureza cooperativa dos pelotões amplifica o impacto de ataques bem-sucedidos. Esse trabalho reforça a necessidade de mecanismos de detecção mais eficientes para lidar com ataques sofisticados, como os de *False Data Injection*, motivando abordagens que equilibrem eficácia de detecção com baixo overhead operacional.

A revisão conduzida em Houssein (2024) [1] analisa de forma detalhada os benefícios e desafios relacionados à segurança em pelotões veiculares. Os autores reportam que esses sistemas têm potencial para reduzir até 90% dos acidentes, gerar economias anuais de aproximadamente $190 bilhões, diminuir significativamente o consumo energético e aumentar a capacidade das vias. No entanto, a concretização desses benefícios depende diretamente da mitigação de vulnerabilidades de segurança cibernética.

O estudo identifica cinco categorias principais de defesa: (a) sistemas baseados em chaves públicas/privadas, que previnem ataques de *sniffing*, *replay* e modificação, mas ainda carecem de avaliações em larga escala; (b) *Road-Side Units* (RSUs), que auxiliam na detecção de ataques de *masquerade* e modificação por meio do monitoramento de comportamento de direção, embora exijam investigações adicionais sobre a segurança da rede de RSUs; (c) algoritmos de controle — categoria particularmente relevante para este trabalho — capazes de detectar comportamentos anômalos e monitorar sensores embarcados, atuando contra ataques de *replay*, modificação, DoS e Sybil, mas com lacunas quanto à localização ideal de implementação; (d) comunicações híbridas, que combinam ondas de rádio com luz visível para mitigar *jamming* e modificação; e (e) segurança de sistemas embarcados, voltada à prevenção de *malware* e ataques de *spoofing/jamming* a sensores.

A abordagem proposta neste trabalho — detecção de ataques FDI utilizando *Reinforcement Learning* — insere-se diretamente na categoria de algoritmos de controle destacada em [1], contribuindo para superar a lacuna relacionada à implementação eficiente de mecanismos de detecção. Em particular, a estratégia de detecção intrínseca baseada em dados de comunicação já disponíveis oferece uma alternativa de baixo overhead ao aproveitar informações coletadas pelos próprios sensores embarcados.

Além disso, [1] introduzem o conceito de *string stability* como métrica fundamental para avaliação de pelotões veiculares. Um sistema é considerado *string stable* quando perturbações entre veículos são atenuadas à medida que se propagam ao longo do pelotão. Os autores identificam fatores que favorecem a estabilidade — como número maior de veículos autônomos, espaçamento adequado e capacidade de antecipação — e fatores que promovem instabilidade, como limites de *jerk*, atrasos e tempo de reação total. Essa métrica é particularmente relevante para sistemas de detecção de ataques, dado que ataques FDI frequentemente se manifestam por meio da degradação da *string stability*. Embora a implementação completa dessa análise esteja além do escopo desta fase inicial, reconhece-se seu potencial como métrica complementar às métricas clássicas de classificação (acurácia, sensibilidade e especificidade), representando uma direção promissora para trabalhos futuros.

B. Abordagens com Reinforcement Learning para Cibersegurança

A aplicação de *Reinforcement Learning* para detecção de ataques cibernéticos em sistemas veiculares representa uma área de pesquisa emergente, com trabalhos recentes demonstrando viabilidade técnica e vantagens operacionais sobre abordagens tradicionais.

Sultana et al. (2024) [3] apresentam uma abordagem baseada em Deep Reinforcement Learning para detecção de múltiplos ataques em VANETs, incluindo False Data Injection, DoS, Replay e Sybil. O método utiliza um agente distribuído, executado localmente em cada veículo, capaz de identificar comportamentos anômalos sem depender de infraestrutura fixa (como RSUs) ou rótulos supervisionados durante o treinamento.

Os autores estruturam o problema como um MDP e empregam um modelo do tipo DQN, que aprende a distinguir mensagens plausíveis de mensagens maliciosas a partir de verificações físicas de consistência. Um ponto forte do trabalho é o mecanismo adaptativo, que permite ao agente ajustar-se dinamicamente a mudanças no contexto da rede, mantendo bom desempenho em cenários de diferentes densidades.

Nos experimentos, conduzidos nos cenários VeReMi Extension e Jaipur, a abordagem obteve desempenho superior a técnicas supervisionadas tradicionais, atingindo acurácia próxima de 96% e F1-score acima de 93%. Apesar disso, o método depende fortemente de heurísticas de verificações físicas pré-definidas e não considera ataques direcionados a dinâmicas cooperativas de pelotões, o que limita a aplicabilidade em sistemas de controle coordenado como os estudados neste trabalho.

Este estudo é particularmente relevante para o presente trabalho pois demonstra a viabilidade do uso de *Reinforcement Learning* na detecção de ataques FDI em ambientes veiculares dinâmicos, explorando recompensas não supervisionadas, aprendizado adaptativo e detecção descentralizada. Para o contexto de pelotões veiculares, os conceitos propostos – como o *speed boundary check* na função de recompensa e o gatilho de atualização baseado em variação de velocidade média – podem ser adaptados para definir políticas de detecção mais robustas, integrando também métricas de *string stability* e coerência do pelotão. O trabalho de Sultana et al. fornece o *baseline* mais próximo da abordagem aqui desenvolvida, permitindo comparações diretas entre o DQN (*value-based*, *off-policy*) e o PPO (*policy-based*, *on-policy*) proposto neste trabalho, tanto em desempenho de detecção quanto em estabilidade e aplicabilidade em pelotões autônomos.

Em uma perspectiva complementar, Raio et al. (2023) [5] investigam o uso de *Reinforcement Learning* para agentes autônomos de ciber-defesa em plataformas veiculares, com foco na proteção do barramento CAN contra injeção maliciosa de mensagens. Os autores utilizam um agente A2C integrado ao testbed Toyota PASTA, no qual o agente aprende a permitir ou bloquear mensagens com base em representações temporais do tráfego CAN. A abordagem explora a capacidade do RL de se adaptar a padrões de ataque variáveis, superando métodos estáticos e modelos supervisionados em termos de resiliência operacional.

Os resultados mostram que o agente obteve desempenho superior na métrica QMoCR, refletindo maior robustez sob ataques de alta frequência. No entanto, o método é fortemente dependente do ambiente específico de treino e foca apenas no nível de barramento, não abrangendo dinâmicas cooperativas entre veículos ou ataques que exploram o comportamento coletivo de sistemas coordenados, como pelotões veiculares.

Para o contexto de pelotões veiculares, conceitos chave são diretamente aplicáveis: transformação de mensagens V2V em representação estruturada para processamento via CNN, uso de *observation dropping*, definição de recompensas considerando *string stability* e coerência do pelotão, expansão de ações para detecção e notificação de alertas, e treinamento com ataques coordenados entre veículos. As limitações identificadas pelos autores – treinamento offline, arquitetura *on-path*, foco apenas em injeção e falhas em transferência sim-to-real – constituem desafios relevantes também para a presente pesquisa, direcionando desenvolvimentos futuros em aprendizado online, refinamento da função de recompensa via métricas de resiliência e *curriculum learning* multi-agente.

Já em uma linha de investigação mais voltada à geração de ameaças do que à detecção, Vyas et al. (2024) [8] exploram o uso de *Reinforcement Learning* para produzir ataques adversariais em pelotões veiculares conectados e autônomos. O objetivo central do estudo é avaliar a vulnerabilidade de controladores cooperativos ao expor o sistema a perturbações estrategicamente aprendidas, em vez de ataques arbitrários ou manualmente projetados.

Os autores utilizam um agente de RL treinado para manipular sinais de controle injetados no veículo líder, buscando maximizar a instabilidade induzida no pelotão. O ambiente segue a modelagem tradicional de controle longitudinal, e o agente aprende políticas de ataque capazes de explorar fragilidades específicas dos controladores de acompanhamento, como sensibilidade a ruído, atrasos e acoplamentos dinâmicos. Os experimentos demonstram que ataques aprendidos via RL são significativamente mais eficazes que perturbações estocásticas, levando a maiores oscilações de velocidade, amplificação de erros e perda de *string stability*.

Embora o estudo não trate de mecanismos defensivos, seus resultados são particularmente relevantes para pesquisas em detecção de FDIAs em pelotões, pois mostram que adversários inteligentes podem explorar propriedades sutis do sistema dinâmico — e não apenas violações explícitas de plausibilidade — para comprometer a estabilidade coletiva. Esse tipo de ataque é substancialmente mais difícil de detectar com verificações físicas convencionais, reforçando a necessidade de mecanismos de detecção sensíveis ao comportamento cooperativo e capazes de capturar padrões temporais complexos.

C. Outros Usos de RL em Pelotões Veiculares

Prathiba et al. (2021) [9] investigam o uso de abordagens híbridas para formação inteligente de pelotões veiculares, combinando *Deep Reinforcement Learning* (DRL) com Algoritmos Genéticos (GA) para superar limitações de desempenho observadas em métodos puramente baseados em aprendizado por reforço. O estudo utiliza a mesma *stack* de simulação deste trabalho — Plexe, SUMO e OMNeT++ — focando na coordenação eficiente entre veículos autônomos, com ênfase na otimização de espaçamento e estabilidade do pelotão.

Os autores identificam que algoritmos de DRL tradicionais apresentam convergência lenta e comportamento sensível à escolha de hiperparâmetros, tornando o processo de aprendizado inadequado para cenários dinâmicos de trânsito. Para mitigar essa limitação, o trabalho propõe um mecanismo híbrido no qual o GA atua como otimizador externo, ajustando parâmetros críticos do DRL e fornecendo políticas iniciais mais eficientes, acelerando significativamente o treinamento. A combinação permite reduzir o tempo até a estabilização do pelotão, melhorar o controle longitudinal e obter decisões mais robustas em condições adversas de tráfego.

Embora a abordagem apresente ganhos importantes em eficiência e estabilidade, o estudo é voltado exclusivamente para a otimização da formação do pelotão, sem considerar aspectos de segurança cibernética ou ataques que possam comprometer as dinâmicas cooperativas entre veículos. Ainda assim, o trabalho oferece insights relevantes para esta pesquisa, especialmente quanto ao uso de técnicas híbridas para acelerar a convergência de modelos baseados em RL e à viabilidade de integração de DRL em sistemas veiculares complexos. Tais elementos podem ser adaptados futuramente para acelerar o treinamento de detectores de ataques FDI ou para compor arquiteturas multiagentes em contexto de segurança para pelotões.

Trinh et al. (2022) [10] investigam o uso de *Deep Reinforcement Learning* para otimizar o fluxo de pelotões veiculares em interseções sinalizadas sob tráfego misto, considerando detecção parcial: apenas veículos conectados (CVs) são observáveis pelo sistema de controle da interseção. O problema é formulado como um MDP e resolvido por meio de um agente DQN operando sobre uma representação espacial compacta (*Discrete Traffic State Encoding* — DTSE), que descreve a ocupação da via em células binárias distribuídas ao longo das aproximações da interseção. As ações consistem na seleção da fase semafórica, enquanto a recompensa mede a redução do tempo de espera cumulativo dos veículos.

A abordagem é avaliada em ambiente SUMO com formação explícita de pelotões via Simpla, variando o tamanho dos pelotões e a taxa de penetração de CVs. Os resultados mostram que o modelo supera técnicas de controle baseadas em sensores tradicionais, reduzindo o tempo médio de espera em até 20–28% para pelotões de três veículos. Entretanto, o desempenho é fortemente dependente da taxa de penetração de CVs: abaixo de 20%, o agente apresenta grande instabilidade devido à escassez de informações observáveis, enquanto com 100% de CVs o ganho de desempenho é até seis vezes superior.

Embora o estudo não aborde segurança cibernética, suas contribuições são relevantes para o contexto de detecção de ataques FDI em pelotões. A representação DTSE oferece um modelo de estado espacial que pode ser adaptado para incorporar sinais de anomalia comportamental; a análise de sensibilidade à penetração de CVs fornece diretrizes para cenários com observabilidade parcial; e os trade-offs entre tamanho do pelotão, atraso e estabilidade podem ser estendidos para métricas como *string stability* em cenários adversariais. Assim, o trabalho fornece um baseline metodológico complementar, demonstrando a viabilidade de arquiteturas DRL em ambientes de tráfego cooperativo e servindo como referência para o desenvolvimento de detectores de FDI em pelotões.

D. Detecção de Ataques FDI em Pelotões

Esta subseção examina trabalhos que abordam especificamente o problema de detecção de ataques de *False Data Injection* em pelotões veiculares – cenário que constitui o foco central desta pesquisa. Diferentemente das abordagens gerais para VANETs discutidas anteriormente, os trabalhos aqui apresentados consideram as dinâmicas cooperativas específicas de pelotões, incluindo aspectos como topologia de comunicação, controle longitudinal coordenado e *string stability*. A análise destes estudos revela tanto os avanços recentes quanto as lacunas que motivam a abordagem baseada em *Reinforcement Learning* proposta neste trabalho.

1) Detecção Baseada em Observadores de Estado: Ahmed et al. (2024) [6] propõem uma estrutura abrangente para detecção, identificação e mitigação de ataques FDI em pelotões veiculares, independentemente da topologia de comunicação adotada. Os autores identificam uma lacuna significativa na literatura: trabalhos anteriores baseados em aprendizado profundo dependem excessivamente de sensores específicos (LiDAR, RADAR) ou são limitados a topologias particulares, além de assumirem que certos parâmetros (como posição) não podem ser manipulados.

A abordagem proposta consiste em dois mecanismos complementares operando em cada veículo. Primeiramente, define-se um modelo de estado geral para o pelotão sob possíveis ataques, flexível o suficiente para acomodar qualquer tamanho de pelotão e qualquer topologia de fluxo de informação (*Information Flow Topology*). Em seguida, projeta-se um *Unknown Input Observer* (UIO) para cada veículo, denominado *Detection UIO*, construído de forma a eliminar as entradas manipuladas do próprio veículo, tornando-o sensível apenas a ataques dirigidos àquele agente e naturalmente insensível aos ataques sofridos pelos demais. A partir desse observador, calcula-se uma função de resíduo que compara os estados recebidos com as estimativas do UIO: valores elevados indicam ataque, enquanto valores próximos de zero indicam operação normal.

Uma vez detectado o ataque, o *framework* aciona um segundo observador, o *Identification UIO*, cujo objetivo é estimar diretamente as entradas de ataque e, assim, identificar quais parâmetros foram manipulados. Por fim, a etapa de mitigação substitui os valores corrompidos por estimativas autênticas fornecidas pelo próprio observador, garantindo que o veículo continue operando de forma segura apesar da manipulação.

A eficácia da abordagem foi demonstrada através de cinco cenários de simulação em MATLAB, explorando diferentes configurações de pelotão e padrões de ataque. O Cenário 1 estabeleceu a linha de base sem ataques, confirmando que as funções de resíduo permanecem próximas de zero em condições normais. O Cenário 2 demonstrou a capacidade do sistema de detectar ataques no veículo líder mesmo a partir de um veículo distante usando topologia PF (*Predecessor Following*), com o *Identification UIO* estimando com precisão as entradas de ataque e permitindo mitigação efetiva. O Cenário 3 testou uma situação complexa envolvendo a fusão de um novo veículo no pelotão simultaneamente a um ataque furtivo em outro veículo, mostrando que o *framework* consegue se adaptar à mudança na topologia e ainda detectar manipulações graduais em múltiplos parâmetros (posição, velocidade e aceleração). O Cenário 4 avaliou ataques coordenados em múltiplos veículos, confirmando que o sistema identifica corretamente todos os veículos comprometidos e estima com precisão todas as entradas de ataque simultaneamente. Finalmente, o Cenário 5 validou a detecção de ataques em veículos seguidores.

Apesar dos resultados promissores, o trabalho apresenta limitações importantes. A primeira diz respeito à dependência do modelo matemático completo do pelotão: cada veículo precisa conhecer os parâmetros de todos os demais (ganhos de controle, matrizes de sistema, constantes de tempo) para construir os observadores, o que pode ser problemático em pelotões heterogêneos ou com veículos entrando e saindo dinamicamente. Em segundo lugar, embora o artigo mencione a robustez contra ruídos de processo e medição, a maior parte das simulações foi conduzida em cenários ideais sem ruído, limitando a avaliação prática da abordagem. Além disso, o próprio artigo reconhece que o *framework* pode gerar alarmes falso-positivos em casos de mau funcionamento, embora argumente que a estratégia de mitigação protege os passageiros mesmo nesses casos. Outro ponto crítico é a ausência de validação experimental em *hardware-in-the-loop* ou veículos reais – todos os resultados são baseados exclusivamente em simulações MATLAB. Por fim, o artigo não discute aspectos práticos de implementação, como o custo computacional dos múltiplos UIOs rodando em tempo real ou a latência introduzida pelo atraso necessário para a estimação.

2) Detecção Não Supervisionada Baseada em Análise de Vizinhança: Borah et al. (2025) [4] apresentam uma abordagem não supervisionada para mitigação de ataques de falsificação de informações em VANETs, com aplicabilidade direta a pelotões veiculares. O trabalho é particularmente relevante para esta pesquisa por utilizar a mesma *stack* de simulação (SUMO, OMNeT++, Veins) e abordar o mesmo problema fundamental de detecção de FDI, porém através de técnica de aprendizado não supervisionado baseada em análise de vizinhança e votação cooperativa.

A metodologia proposta opera em duas fases principais. Na primeira fase, cada veículo analisa as informações reportadas por seus vizinhos, calculando desvios estatísticos em relação aos valores esperados com base na física do movimento e nas condições de tráfego observadas. Especificamente, o algoritmo compara a velocidade reportada por cada vizinho com a velocidade média da vizinhança e com predições baseadas no modelo cinemático, identificando veículos cujos valores excedem limiares de desvio pré-estabelecidos. Na segunda fase, implementa-se um mecanismo de votação cooperativa no qual múltiplos veículos compartilham suas avaliações sobre potenciais atacantes, reduzindo falsos positivos através de consenso distribuído.

Os experimentos foram conduzidos em cenários urbanos realistas utilizando mapas reais de Bangalore, Índia, com diferentes densidades de tráfego e taxas de penetração de veículos maliciosos. O método alcançou acurácia superior a 92% na detecção de veículos comprometidos, com taxa de falsos positivos mantida abaixo de 8% em condições normais de operação. Os resultados demonstram particular robustez em cenários com até 30% de veículos maliciosos, mantendo desempenho aceitável mesmo em condições adversas.

As limitações identificadas pelos autores incluem: (i) a premissa de maioria honesta, assumindo que a maior parte dos veículos na vizinhança reporta informações legítimas; (ii) degradação de desempenho com taxas de penetração de atacantes superiores a 30%, embora os autores argumentem que tal cenário seja irrealista em aplicações práticas; (iii) variações naturais de velocidade em condições de tráfego dinâmico podem ocasionalmente causar falsos positivos, embora a taxa observada seja baixa; e (iv) o método concentra-se especificamente em falsificação de velocidade, não tratando outros tipos de manipulação de dados.

Este trabalho oferece um *baseline* valioso para comparação com a abordagem baseada em *Reinforcement Learning* proposta nesta pesquisa. Enquanto o método de Borah et al. baseia-se em regras de detecção de anomalias estatísticas, a abordagem de RL tem potencial para capturar padrões temporais mais complexos, considerar múltiplos parâmetros simultaneamente e adaptar-se dinamicamente a diferentes tipos de FDI através do aprendizado de políticas de detecção.

3) Detecção Baseada em Fusão de Dados na Nuvem: Zhao et al. (2021) [7] investigam a detecção de ataques FDI em veículos conectados e autônomos através de estratégia baseada em nuvem (*cloud-based*), explorando a viabilidade de conectividade 5G e infraestrutura de computação veicular na nuvem. A abordagem parte das premissas de que latência inferior a 0,4s é aceitável para aplicações veiculares críticas e que a infraestrutura 5G combinada com nuvem veicular viabiliza *streaming* de dados em tempo real dos veículos para processamento centralizado.

A arquitetura proposta segue o fluxo: Veículos → V2I → Nuvem (Fusão de Dados + Detecção de Ataques) → Decisão (Aceitar/Rejeitar) → Veículos. A ideia central baseia-se em localização cooperativa (*cooperative localization*): para estimar a posição e a velocidade reais de um veículo, o sistema compara os dados próprios com os dos vizinhos, levando em conta também o modelo físico do movimento. Assim, se um veículo reporta valores muito diferentes dos esperados fisicamente, isso indica possível ataque.

O método de fusão de dados é baseado em Filtro de Partículas (*Particle Filter*), executado em ambiente de nuvem. Cada veículo possui um filtro que combina dados de GPS, sensores inerciais e informações recebidas via V2V. Em condições normais, as posições e velocidades estimadas pelos veículos e pelos vizinhos são coerentes. Quando um atacante injeta dados falsos (por exemplo, posição deslocada ou velocidade adulterada), o filtro de partículas identifica as partículas inconsistentes (baixa probabilidade), reduz seu peso e sinaliza o veículo como suspeito. A detecção ocorre com latência inferior a 0,4s, garantindo viabilidade prática em aplicações veiculares.

O estudo introduz dois algoritmos complementares: para *platooning*, utiliza pesos de partículas baseados na coerência entre veículos do pelotão, isolando nós que reportam valores fisicamente incoerentes; para *rerouting*, trata cada veículo como um sensor adicional e combina múltiplas medições via fusão probabilística, detectando falsificação de informações sobre tráfego e tempo de rota.

Nos experimentos simulados (VISSIM + MATLAB + Azure Cloud), o método alcançou taxa de detecção acima de 95% e taxa de falsos positivos inferior a 5%, mantendo estabilidade no pelotão mesmo durante ataques. Os autores utilizam *binary hypothesis testing* para definir o limiar ótimo de detecção e implementam lógica de decisão cooperativa via votação majoritária, combinando decisões de múltiplos veículos para aumentar robustez.

Embora a abordagem demonstre alta eficácia, apresenta limitações práticas significativas: (i) dependência de infraestrutura de nuvem e conectividade 5G confiável, o que pode não estar disponível em todas as regiões; (ii) latência de comunicação veículo-nuvem-veículo, mesmo sendo inferior a 0,4s, pode ser crítica em situações de emergência; (iii) o processamento centralizado na nuvem constitui ponto único de falha e potencial alvo de ataques; e (iv) custos operacionais associados à transmissão contínua de dados e processamento na nuvem. Em contraste, a abordagem baseada em RL proposta neste trabalho opera de forma distribuída em cada veículo, eliminando dependências de infraestrutura externa e reduzindo latências de comunicação.

V. EXPLORAÇÃO DE OTIMIZAÇÃO DOS RESULTADOS DE RL

A otimização dos resultados iniciais de Reinforcement Learning constituiu um dos focos principais deste projeto de POC 1. Esta seção detalha a metodologia de exploração para melhoria do desempenho do detector, estruturada em duas frentes complementares: busca sistemática de hiperparâmetros e refinamento da função de recompensa. Os resultados obtidos são apresentados na Seção VIII.

A. Busca de Hiperparâmetros

O treinamento inicial foi configurado com os seguintes parâmetros principais:

TABLE I

COMPARAÇÃO ENTRE ABORDAGENS DE DETECÇÃO DE ATAQUES FDI EM REDES VEICULARES

Trabalho	**Técnica**	**Contexto**	**Acurácia**	**Online**	**Pelotões**
Sultana et al. (2024) [3]	DQN	VANETs gerais	96%	Sim	Não
Raio et al. (2023) [5]	A2C	Barramento CAN	N/R	Sim	Não
Vyas et al. (2024) [8]	RL adversarial	Pelotões	N/A	Sim	Sim
Prathiba et al. (2021) [9]	DRL + GA	Formação pelotões	N/R	Sim	Sim
Trinh et al. (2022) [10]	DQN	Intersecções	N/R	Sim	Sim
Ahmed et al. (2024) [6]	UIOs	Pelotões	95%	Sim	Sim
Zhao et al. (2021) [7]	Particle Filter	Veículos conectados	95%	Sim	Sim
Borah et al. (2025) [4]	Anomalia + Votação	VANETs	92%	Sim	Não
Este trabalho	**PPO**	**Pelotões**	**52,6%**	**Não**	**Sim**

N/R: Não reportado; N/A: Não aplicável.
UIOs: Unknown Input Observers; DQN: Deep Q-Network; A2C: Advantage Actor-Critic.
PPO: Proximal Policy Optimization; DRL: Deep Reinforcement Learning; GA: Algoritmos Genéticos.

- **Timesteps totais**: 500.000 (aumentado de 100.000 após análises preliminares indicarem convergência insuficiente);
- **Duração do episódio**: 600 timesteps por episódio;
- **Fonte de dados**: dataset com 9.000 amostras balanceadas (aproximadamente 50% de ataques);
- **Dimensão do espaço de observação**: 8 características (features) extraídas dos dados de simulação;
- **Learning rate**: 3×10^{-4} (valor padrão do PPO);
- **Batch size**: 64 observações;
- **Arquitetura da rede neural**: MLP com duas camadas ocultas de 64 neurônios cada, utilizando ativação ReLU.

E função de recompensa balanceada:

$$R = \begin{cases} +1.0, & \text{detecção correta} \\ -0.9, & \text{falso positivo} \\ -1.0, & \text{falso negativo} \\ -0.2, & \text{incerteza} \end{cases}$$

A exploração inicial de hiperparâmetros foi conduzida dentro do ambiente virtualizado, utilizando treinamento em CPU. Esta abordagem, embora viável para validação conceitual, apresentou limitações significativas: cada execução de treinamento completo (500.000 timesteps) demandava muito tempo, inviabilizando busca exaustiva de hiperparâmetros. Consequentemente, a exploração inicial concentrou-se em variações pontuais dos parâmetros mais críticos (*learning rate* e arquitetura de rede), avaliando impacto qualitativo na convergência.

Os resultados preliminares evidenciaram necessidade de exploração mais sistemática, motivando migração do treinamento para ambiente fora da VM, além de aceleração por GPU. A transição para GPU reduziu o tempo de treinamento, viabilizando busca mais abrangente de hiperparâmetros - embora isso tenha exigido reestruturar o código para execução em GPU, o que adicionou algum atraso ao desenvolvimento.

1) Diferenças entre Implementação CPU e GPU: A migração de CPU para GPU introduziu considerações técnicas importantes que influenciaram tanto o processo de treinamento quanto os resultados obtidos. Primeiramente, o processamento paralelo em GPU altera a ordem de execução de operações estocásticas – particularmente amostragem de *minibatches* e inicialização de pesos da rede neural – resultando em trajetórias de treinamento diferentes mesmo quando utilizando mesma *seed* aleatória. Esta característica é documentada em frameworks de aprendizado profundo e constitui comportamento esperado, não indicando problemas de implementação.

Adicionalmente, operações de ponto flutuante em GPU utilizam precisão numérica ligeiramente diferente de CPU, particularmente em operações de redução (somas, médias) sobre grandes tensores. Embora estas diferenças sejam tipicamente negligenciáveis em termos absolutos ($\approx 10^{-6}$ a 10^{-7}), podem acumular-se ao longo de milhares de atualizações de gradiente, resultando em divergências mensuráveis nas políticas aprendidas.

Uma consequência prática observada foi variabilidade ligeiramente maior na convergência entre execuções em GPU comparadas a CPU. Enquanto treinamentos em CPU apresentavam trajetórias de convergência relativamente reprodutíveis (assumindo mesma *seed*), execuções em GPU com configurações idênticas ocasionalmente divergiam após centenas de milhares de timesteps. Esta observação reforçou a necessidade de executar treinamentos com repetições e episódios mais longos.

2) Espaço de Busca de Hiperparâmetros: A busca de hiperparâmetros explorou valores em torno da configuração inicial, expandindo sistematicamente o espaço de busca conforme indicado na Tabela II.

Os hiperparâmetros selecionados para exploração foram escolhidos com base em sua influência documentada sobre diferentes aspectos do treinamento. O *learning rate* controla a magnitude das atualizações de política, influenciando diretamente velocidade de convergência e estabilidade. *Batch size* e número de épocas determinam eficiência amostral e qualidade de estimativas de gradiente. *Clip range* limita magnitude de mudanças de política, constituindo mecanismo central de estabilização do PPO. GAE lambda controla *bias-variance tradeoff* em estimativas de vantagem. *Entropy coefficient* incentiva exploração ao penalizar políticas determinísticas. *Value function coefficient* balanceava importância relativa entre

Hiperparâmetro	**Valores testados**
Learning rate	{1e-4, 3e-4, 5e-4, 1e-3}
Batch size	{32, 64, 96, 128}
Número de épocas	{10, 15, 20, 25}
Clip range	{0.1, 0.15, 0.2}
GAE lambda	{0.95, 0.98, 0.99}
Entropy coefficient	{0.0, 0.01, 0.02}
Value function coef	{0.25, 0.5, 0.75}
Arquiteturas	{[128,128], [256,128], [128,128,64], [256,256], [512,256,128]}

TABLE II

ESPAÇO DE BUSCA DE HIPERPARÂMETROS EXPLORADO DURANTE OTIMIZAÇÃO DO MODELO PPO.

aprendizado de política e função de valor. Finalmente, arquiteturas de rede determinam capacidade de representação do modelo.

Devido ao tamanho total do espaço de busca (25920 combinações), tornou-se impraticável avaliar todas as configurações. Assim, adotou-se uma estratégia em duas etapas. Primeiro, aplicou-se *grid search* limitado ao número máximo de combinações viáveis dentro do orçamento computacional disponível. Em seguida, as cinco configurações mais promissoras—selecionadas com base no desempenho preliminar—foram retreinadas com maior número de episódios e avaliação mais rigorosa, permitindo identificar o conjunto final de hiperparâmetros com maior confiabilidade.

B. Melhoria da Função de Recompensa

O aprofundamento nos fundamentos teóricos de *Reinforcement Learning*, particularmente através da disciplina específica sobre o tema cursada neste semestre, propiciou compreensão mais refinada dos mecanismos de aprendizado do agente PPO e das limitações da abordagem inicial. Esta análise revelou que a função de recompensa implementada – embora balanceada em termos de penalizações relativas entre falsos positivos e falsos negativos – não capturava adequadamente a natureza temporal e sequencial do problema de detecção de ataques FDI.

A função de recompensa inicial operava de forma instantânea, atribuindo penalidades ou recompensas isoladas a cada decisão do agente sem considerar consequências temporais. Especificamente, um falso positivo recebia penalização única de -0,9 no timestep em que ocorria, independentemente de seus efeitos propagados sobre a estabilidade do pelotão nos timesteps subsequentes. Esta modelagem inadequada manifestava-se nos resultados através de comportamento excessivamente conservador do agente (especificidade de apenas 35,6%), indicando que o modelo não aprendia a distinguir efetivamente entre alarmes legítimos e situações normais de operação.

1) Modelagem de Recompensas Temporais: Para endereçar estas limitações, desenvolveu-se sistema de recompensas temporais (*temporal rewards*) que incorpora contexto temporal das decisões e seus impactos sobre a formação veicular. A ideia central consiste em transformar decisões incorretas – que antes geravam penalização pontual – em eventos que desencadeiam sequências de penalizações ou bonificações baseadas nas consequências observadas ao longo do tempo.

O sistema temporal implementa cinco mecanismos complementares:

(i) Rastreamento temporal de decisões incorretas: O ambiente mantém histórico das decisões do agente, identificando falsos positivos e falsos negativos e monitorando sua duração. Quando o agente comete erro, este é registrado com timestamp, permitindo que consequências sejam atribuídas corretamente mesmo quando manifestam-se timesteps após a decisão original.

(ii) Análise de formação veicular: A cada timestep, o sistema analisa métricas de estabilidade do pelotão – incluindo desvio de velocidade em relação ao líder, distâncias interveiculares e gaps temporais – determinando se a formação está intacta ou degradada. Esta análise fundamenta-se na premissa de que decisões incorretas manifestam-se através de degradação mensurável da coordenação cooperativa. A formação é considerada intacta quando o desvio total nas métricas monitoradas permanece abaixo de 20%, limiar inicial para exploração dos resultados, que poderá ser ajustado no futuro.

(iii) Penalização contínua até recuperação: Enquanto consequências de decisão incorreta persistem – por exemplo, quando a formação permanece degradada após falso positivo – o agente recebe penalização temporal contínua a cada timestep. Esta penalização é substancialmente menor que a penalização inicial (tipicamente 10-20% do valor inicial), mas acumula-se ao longo do tempo, criando incentivo forte para que o agente aprenda a evitar decisões cujas consequências prolongam-se temporalmente.

(iv) Incentivos de recuperação: Quando o agente toma decisão que restaura estabilidade do pelotão – por exemplo, detecta ataque que vinha sendo ignorado ou reconhece que situação anterior não era ataque – recebe bonificação de recuperação. Esta bonificação compensa parcialmente as penalizações temporais acumuladas, incentivando comportamento corretivo.

(v) Decaimento temporal das penalidades: Penalizações temporais decaem exponencialmente ao longo do tempo através de fator de decaimento (tipicamente 0,9-0,95), reconhecendo que consequências de decisões antigas tornam-se progressivamente menos relevantes. Este mecanismo previne que erros antigos dominem indefinidamente o sinal de aprendizado.

2) Configurações Implementadas: Foram inicialmente testados três perfis de configuração temporal, variando na severidade das penalizações, intensidade das penalizações temporais e generosidade das bonificações. Esses perfis — conservador, balanceado e agressivo — permitiram avaliar diferentes combinações entre punições imediatas, acúmulo temporal de consequências e incentivos para recuperação. No entanto, experimentos preliminares indicaram que tais configurações não produziam melhorias significativas no desempenho do agente, motivando uma exploração mais ampla do espaço de parâmetros.

Essa exploração sistemática investigou cinco famílias de configurações, cada uma orientada por hipóteses distintas sobre as possíveis causas do comportamento subótimo observado.

A primeira família examinou o impacto de recompensas desbalanceadas entre detecção de ataques e classificação correta de tráfego normal, variando a priorização entre esses dois objetivos e ajustando penalizações associadas a falsos positivos e falsos negativos.

A segunda família concentrou-se na severidade e duração das penalizações, testando desde punições imediatas muito fortes até esquemas baseados em penalizações temporais prolongadas.

A terceira família avaliou o papel das bonificações de recuperação, variando sua magnitude e assimetria para verificar se incentivos corretivos poderiam acelerar o aprendizado. A quarta investigou parâmetros temporais do sistema, incluindo tamanho da memória, duração máxima das penalidades e taxa de decaimento, buscando identificar configurações que facilitassem a associação entre decisões e consequências ao longo do tempo. Por fim, a quinta família experimentou um enfoque alternativo baseado na priorização de recompensas positivas, reduzindo ou até eliminando penalizações temporais para incentivar exploração mais ampla pelo agente.

Ao todo, aproximadamente quinze configurações distintas foram avaliadas, cobrindo combinações representativas das hipóteses levantadas. Embora nenhuma delas tenha produzido melhorias substanciais nesta etapa, o processo revelou forte sensibilidade do aprendizado às escolhas de modelagem de recompensa e forneceu direções promissoras para investigação futura.

3) Implementação: A incorporação do sistema temporal exigiu ajustes estruturais no ambiente de treinamento. Foi introduzido um módulo responsável por acompanhar a dinâmica temporal do agente, analisando estabilidade da formação veicular e ajustando a recompensa de acordo com o comportamento observado ao longo do tempo.

O ambiente foi estendido para integrar esse módulo, permitindo habilitar diferentes configurações temporais e combinando o sinal de recompensa instantâneo com ajustes baseados em histórico e consistência operacional. Para isso, passou a extrair métricas relevantes da formação do pelotão, como variações de velocidade e distâncias entre veículos, fornecendo insumos para a avaliação temporal.

Por fim, foram incorporados mecanismos de análise que possibilitam comparar diferentes configurações e visualizar seus efeitos no processo de aprendizado, oferecendo uma visão mais clara do impacto do componente temporal no desempenho do agente.

VI. EXPLORAÇÃO DE CENÁRIOS DE TREINAMENTO MAIS REALISTAS

A literatura revisada revela que a eficácia de sistemas de detecção de ataques FDI depende criticamente da representatividade dos cenários utilizados durante o treinamento. Trabalhos recentes identificam limitações significativas em abordagens que utilizam cenários simplificados – como pelotões trafegando em trajetória retilínea com condições ideais de comunicação – apontando para a necessidade de ambientes de treinamento que capturem a complexidade operacional de sistemas veiculares reais. Esta seção examina oportunidades de expansão dos cenários de treinamento, organizadas em cinco dimensões principais: topologia de comunicação, modelos de ataque, dinâmica física, características de comunicação V2V e heterogeneidade de tráfego.

A. Diversificação de Topologias de Comunicação

A topologia de comunicação determina como informações são compartilhadas entre membros do pelotão, influenciando diretamente tanto a propagação de ataques quanto a capacidade de detecção. Ahmed et al. [6] criticam explicitamente a falta de diversidade de topologias na literatura existente, observando que trabalhos anteriores baseados em aprendizado profundo frequentemente limitam-se a topologias específicas, comprometendo a generalização dos modelos treinados.

As principais topologias de fluxo de informação (*Information Flow Topologies* – IFTs) em pelotões incluem: (i) *Predecessor Following* (PF), onde cada veículo recebe informações apenas do predecessor imediato; (ii) *Predecessor-Leader Following* (PLF), onde veículos recebem informações tanto do predecessor quanto do líder; (iii) *Bidirectional* (BD), permitindo comunicação com predecessores e sucessores; e (iv) topologias adaptativas que modificam a estrutura de comunicação dinamicamente baseadas em condições operacionais.

A implementação inicial considera apenas topologia PF em um cenário linear simplificado, mas estender o trabalho para múltiplas topologias exige alterações relevantes: o Plexe precisaria incorporar novos padrões de comunicação, o espaço de observação do agente de RL teria de ser redesenhado, e diferentes topologias afetam de maneira distinta a propagação dos ataques (por exemplo, PLF impacta todos os seguidores imediatamente, enquanto PF propaga efeitos de forma sequencial). Uma análise preliminar indica que a topologia PLF seria a expansão mais viável, pois demandaria modificações mais localizadas no módulo de comunicação do simulador.

B. Modelos de Ataque Mais Sofisticados

Os cenários de ataque utilizados nesta fase inicial focaram apenas em injeção pontual de dados falsos de aceleração, aplicada em momentos aleatórios da simulação. Embora esse modelo capture a essência dos ataques FDI, a literatura aponta que adversários podem agir de formas muito mais sofisticadas. Para que os detectores baseados em RL sejam robustos, é necessário incorporar ataques mais realistas ao processo de treinamento.

Ataques Coordenados entre Múltiplos Veículos: Aataques realizados por múltiplos veículos comprometidos simultaneamente representam um risco maior do que ataques isolados. Nessas situações, diferentes nós manipulam seus dados de forma sincronizada, amplificando o impacto sobre a estabilidade do pelotão e confundindo detectores que assumem apenas um atacante. Para implementar esse tipo de ataque, é necessário um mecanismo de coordenação entre os veículos comprometidos, estratégias de manipulação cooperativas e padrões temporais sincronizados.

Ataques Intermitentes e Furtivos: Outro conjunto relevante de cenários envolve ataques que não ocorrem de maneira contínua. Ataques intermitentes alternam períodos de atividade e inatividade, dificultando detectores baseados em limiares fixos. Já ataques furtivos introduzem pequenas manipulações persistentes — como leves desvios na velocidade reportada — que passam despercebidas por verificações físicas simples, mas degradam o comportamento coletivo ao longo do tempo. Para incorporar esse tipo de ameaça, é necessário definir métricas de furtividade, controlar intensidade e frequência das manipulações e gerar dados que incluam desde alterações bruscas até perturbações sutis.

Efeitos de Degradação da Comunicação: Cenários realistas também devem considerar imperfeições da comunicação V2V. Latência variável, perda de pacotes e dessincronização de relógios são fenômenos esperados em ambientes reais e podem interferir diretamente na detecção. Em alguns casos, imprecisões de comunicação podem mascarar ataques; em outros, podem gerar falsos positivos ao fazer o sistema interpretar atrasos legítimos como manipulação maliciosa. Incluir esses efeitos no ambiente de treinamento seria interessante para que o agente aprenda a distinguir ruído de ataque e evite dependência excessiva de verificações rígidas.

C. Cenários de Tráfego Heterogêneo

A implementação inicial utiliza pelotão homogêneo de oito veículos idênticos trafegando em ambiente isolado. Cenários reais apresentam heterogeneidade substancial em múltiplas dimensões: (i) capacidades de comunicação – nem todos veículos possuem V2V, alguns podem ter comunicação intermitente ou degradada; (ii) características dinâmicas – diferentes modelos de veículos apresentam diferentes capacidades de aceleração e frenagem; (iii) comportamento de controle – veículos podem utilizar diferentes algoritmos de controle longitudinal; e (iv) presença de veículos não cooperativos – tráfego misto inclui veículos humanos que não participam do pelotão.

Borah et al. [4] utilizam cenários urbanos realistas baseados em mapas reais de Bangalore, Índia, incluindo tráfego heterogêneo com diferentes densidades e composições. Os autores observam que a presença de tráfego não cooperativo introduz variabilidade natural no comportamento do pelotão que pode tanto mascarar ataques quanto aumentar taxa de falsos positivos.

D. Treinamento Adversarial

Uma direção promissora identificada na literatura é o uso de treinamento adversarial, onde um agente adversário gera ataques adaptativos enquanto o detector aprende a identificá-los. Vyas et al. [8] demonstram que adversários treinados via RL descobrem estratégias de ataque significativamente mais eficazes que perturbações projetadas manualmente, explorando fragilidades específicas do sistema que podem não ser antecipadas por projetistas humanos.

A implementação de treinamento adversarial requer arquitetura multi-agente onde detector e atacante co-evoluem: o atacante maximiza impacto enquanto minimiza detectabilidade, e o detector maximiza sensibilidade enquanto minimiza falsos positivos. Esta abordagem tem potencial para gerar detectores mais robustos, mas introduz complexidade substancial: o espaço de busca de políticas expande-se significativamente, a convergência torna-se menos previsível, e a avaliação de desempenho requer métricas mais sofisticadas que capturem a dinâmica adversarial.

E. Considerações sobre Implementação e Avaliação

A expansão para cenários mais realistas apresenta desafios metodológicos significativos que devem ser endereçados sistematicamente. Primeiramente, a avaliação do impacto de novos cenários sobre o desempenho do modelo requer que o modelo inicial atinja resultados comparáveis ao estado da arte em cenários simplificados – estabelecendo *baseline* sólido antes de introduzir complexidade adicional. Os resultados preliminares apresentados na Seção VIII, com acurácia de 52,6% e especificidade de 35,6%, indicam que melhorias substanciais são necessárias no modelo base antes de expansão para cenários mais complexos.

Adicionalmente, a avaliação empírica de detectores treinados requer integração online com o simulador – permitindo que o agente tome decisões em tempo real baseadas em observações sequenciais, ao invés de operar sobre dados estáticos pré-gravados. Esta integração pode ser implementada através de interface API entre o agente treinado e o simulador Plexe, embora tal desenvolvimento esteja além do escopo da atual fase exploratória, além de ser considerada tecnicamente complexa.

Uma estratégia metodológica prudente consiste em expansão incremental: após estabelecer desempenho competitivo em cenários simplificados, introduzir complexidade adicional uma dimensão por vez, avaliando sistematicamente o impacto de cada modificação. Esta abordagem permite identificar quais aspectos de realismo têm maior impacto na robustez do detector, direcionando esforços de desenvolvimento de forma eficiente.

VII. EXPLORAÇÃO DE COMPARAÇÃO COM ALGORITMOS ALTERNATIVOS

O resumo abaixo sintetiza os modelos de treinamento empregados pelos principais trabalhos revisados sobre detecção de ataques FDI e aplicações correlatas de Reinforcement Learning em ambientes veiculares.

Reinforcement Learning (4 trabalhos):

- **DQN**: Sultana et al. [3]; Trinh et al. [10]
- **A2C**: Raio et al. [5]
- **RL adversarial**: Vyas et al. [8]

Métodos Híbridos (1 trabalho):

- **DRL + GA**: Prathiba et al. [9]

Técnicas Clássicas (3 trabalhos):

- **UIOs**: Ahmed et al. [6]
- **Particle Filter**: Zhao et al. [7]
- **Distance-based anomaly detection**: Borah et al. [4]

Trabalhos Conceituais (2 trabalhos):

- Taylor et al. [2]; Houssein [1]

Logo, em comparação aos papers revisados, este trabalho é o **primeiro** a aplicar *Proximal Policy Optimization* (PPO) para detecção de FDI em pelotões veiculares, introduzindo uma abordagem *policy-based* e *on-policy* ainda inexplorada na literatura.

A. Análise Comparativa Conceitual

A Tabela III sintetiza as características principais das abordagens revisadas, posicionando o presente trabalho em relação ao estado da arte.

Trabalho	**Abordagem**	**Acurácia**	**Online**	**Pelotões**
Borah et al.	Anomalia	92%	Sim	Não
Sultana et al.	DQN	96%	Sim	Não
Ahmed et al.	UIO	95%	Sim	Sim
Zhao et al.	Particle Filter	95%	Sim	Sim
Este trabalho	**PPO**	**52,6%**	**Não**	**Sim**

TABLE III
COMPARAÇÃO CONCEITUAL ENTRE ABORDAGENS DE DETECÇÃO DE FDI.

B. Identificação de Benchmarks para Validação Futura

Os resultados preliminares obtidos nesta fase exploratória (acurácia de 52,6%, especificidade de 35,6%) estão significativamente abaixo do desempenho reportado por trabalhos consolidados na literatura. Logo, para a fase de POC 2, quando o modelo atingir desempenho competitivo, identificam-se três benchmarks prioritários para comparação experimental:

1) Borah et al. (2025): Constitui o benchmark mais direto disponível pois: (i) aborda o mesmo problema (FDI em VANETs); (ii) utiliza a mesma stack de simulação (SUMO/OMNeT++/Veins); (iii) apresenta resultados recentes e bem documentados (acurácia 92%, FPR $<$ 8%); e (iv) o algoritmo é relativamente simples (detecção de anomalia baseada em distância + votação cooperativa), facilitando reimplementação.

A comparação permitirá avaliar se a complexidade adicional do PPO (captura de padrões temporais, aprendizado de política) justifica-se em relação a métodos mais simples baseados em detecção de anomalias estatísticas.

2) Sultana et al. (2024): Comparação metodológica entre diferentes paradigmas de RL: DQN (value-based, off-policy) versus PPO (policy-based, on-policy). Ambos demonstraram eficácia em detecção de ataques em VANETs, mas apresentam trade-offs distintos em termos de estabilidade de convergência, eficiência amostral e requisitos computacionais.

A implementação e comparação experimental permitirá avaliar qual paradigma de RL é mais adequado para o problema específico de detecção de FDI em pelotões veiculares.

3) Baselines mais Simples - Supervisionado/Não-Supervisionado: A inclusão de baselines clássicos — como Random Forest, SVM ou Isolation Forest — fornecerá uma linha de base inicial para calibrar expectativas e verificar se métodos mais simples já capturam padrões relevantes dos dados. Essa comparação é fundamental para determinar se o uso de RL é de fato necessário ou se modelos tradicionais já oferecem desempenho competitivo.

VIII. RESULTADOS PARCIAIS

Os resultados obtidos nesta fase exploratória foram avaliados segundo duas abordagens distintas: utilizando a função de recompensa simples com busca de hiperparâmetros, e empregando as configurações de recompensas temporais, também combinadas com otimização de hiperparâmetros. Embora esta estruturação dual permita análise comparativa das estratégias exploradas, cabe destacar preliminarmente que os resultados globais permaneceram substancialmente abaixo do desempenho reportado no estado da arte, não atingindo os objetivos de desempenho estabelecidos para aplicações práticas.

A principal dificuldade observada manifesta-se através de comportamento excessivamente conservador do detector: o agente desenvolveu tendência persistente a classificar proporção elevada de observações como ataques, resultando em especificidade inadequada. Verificou-se trade-off aparentemente intrínseco entre sensibilidade e especificidade – melhorias em uma métrica frequentemente correspondiam a degradação na outra, dificultando identificação de configurações que otimizassem ambas simultaneamente. Em casos extremos, determinadas combinações de função de recompensa e hiperparâmetros resultaram em comportamento trivial onde o modelo classificava 100% das observações como ataques, maximizando sensibilidade às custas de especificidade nula.

O desafio fundamental identificado consiste na dificuldade de formular função de recompensa que apresente crescimento consistente ao longo dos episódios de treinamento. Análises das curvas de aprendizado, apresentadas nas subseções subsequentes, revelam que nenhuma das configurações exploradas conseguiu estabelecer trajetória de recompensas médias crescente de forma sustentada. Esta característica – recompensas estagnadas ou oscilantes – constitui, em nossa avaliação, o fator primário responsável pela distância entre os resultados obtidos e o desempenho reportado na literatura. Sem sinal de aprendizado claro (recompensas crescentes), o agente não consegue distinguir políticas superiores de inferiores, convergindo para estratégias subótimas.

A. Resultados com Função de Recompensa Simples

Para ilustrar o comportamento típico observado durante a exploração de hiperparâmetros com função de recompensa simples, apresenta-se análise detalhada da configuração identificada como ID 17, cujos resultados situam-se próximos à mediana do desempenho observado ao longo de todas as configurações testadas.

	Predito Ataque	Predito Normal
Ataque (real)	2289	720
Normal (real)	2224	767

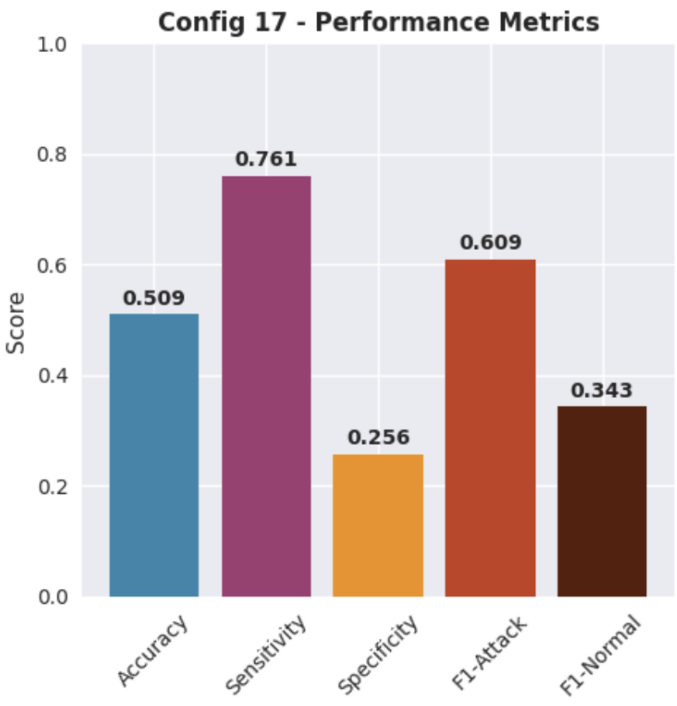

Fig. 2. Métricas de uma configuração mediana do desempenho observado com a função de recompensa simples

A matriz de confusão evidencia o padrão recorrente: quantidade elevada de predições de ataque e indefinição na classificação de tráfego normal. As configurações que apresentaram desempenho ligeiramente superior – discutidas na Subseção VIII-C – distinguiram-se precisamente por capacidade marginalmente melhorada de identificar tráfego normal, reduzindo a taxa de falsos positivos sem comprometer excessivamente a sensibilidade. Esta observação sugere que o gargalo principal reside na capacidade do modelo de aprender características discriminativas de tráfego normal, ao invés de simplesmente adotar estratégia conservadora de classificar observações ambíguas como ataques.

B. Resultados com Temporal Configs

A implementação do sistema de recompensas temporais foi avaliada através de cinco configurações principais, cada uma explorando diferentes estratégias de penalização e incentivos ao longo do tempo. As configurações testadas incluíram: `Learning_V3_Immediate` (penalizações imediatas intensificadas), `Learning_V2_Gradual` (penalizações graduais com decaimento), `Learning_V5_Growth` (incentivos de crescimento progressivo), `Learning_V1_Positive` (foco em recompensas positivas) e `Learning_V4_Exploration` (incentivo à exploração com penalizações reduzidas).

Conforme evidenciado na Figura 3, nenhuma das configurações temporais conseguiu estabelecer uma trajetória de recompensas crescente ao longo dos episódios de treinamento. Todas apresentaram comportamento de estagnação, com recompensas médias oscilando em torno de valores constantes. Este comportamento confirma a hipótese de que o problema fundamental reside na formulação da função de recompensa, e não apenas em ajustes de hiperparâmetros.

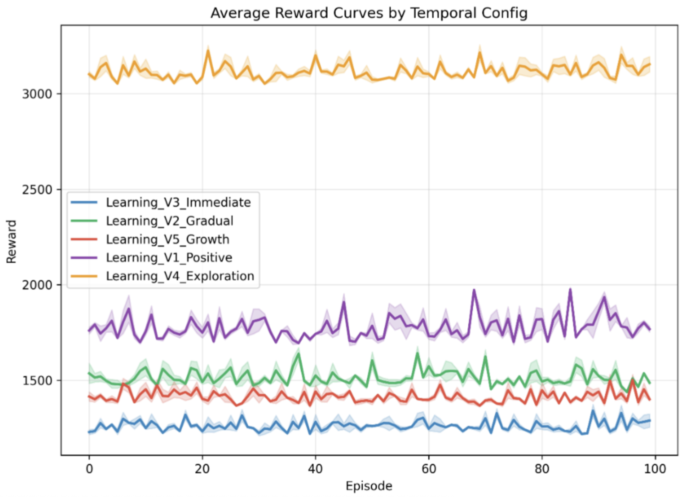

Fig. 3. Curvas de recompensa média para cinco configurações temporais principais. Todas apresentam estagnação, sem evidência de aprendizado progressivo ao longo dos episódios.

A análise da distribuição de acurácia, apresentada na Figura 4, revela convergência das configurações temporais para desempenho similar ao obtido com a função de recompensa simples. A mediana de acurácia situou-se entre 0.504 e 0.512 para todas as configurações, com variabilidade limitada evidenciada pelos *box plots*. Notavelmente, `Learning_V4_Exploration`, apesar de apresentar recompensas médias superiores, não traduziu essa característica em melhoria de acurácia, sugerindo desalinhamento entre o sinal de recompensa e o objetivo de classificação.

O comportamento persistentemente conservador observado nas configurações temporais replica o padrão identificado na função de recompensa simples: tendência sistemática a classificar observações ambíguas como ataques. Esse resultado sugere que as modificações temporais, embora teoricamente fundamentadas, não endereçaram a causa raiz do problema de especificidade inadequada. A incorporação de contexto temporal e consequências de longo prazo não foi suficiente para superar as limitações na capacidade discriminativa do modelo entre tráfego normal e comportamento malicioso.

C. Melhores Resultados

Apesar das limitações identificadas, a configuração que apresentou o melhor desempenho global foi obtida utilizando a função de recompensa simples com otimização de hiperparâmetros, alcançando acurácia de 52,6%. A análise detalhada das métricas de desempenho, apresentada na Figura 5,

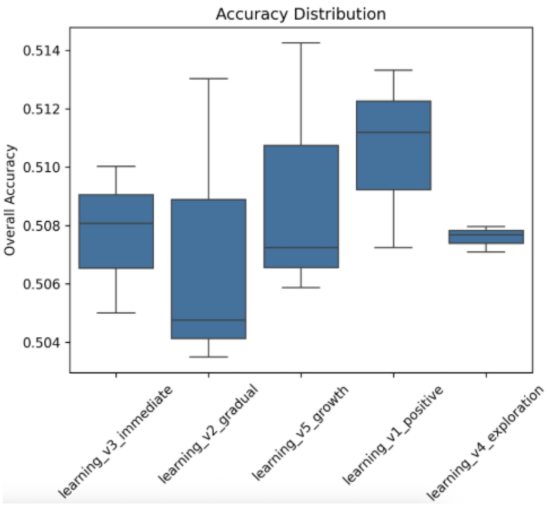

Fig. 4. Distribuição de acurácia para as cinco principais configurações temporais testadas. A convergência para valores similares (0.504–0.512) indica ausência de melhorias substantivas.

evidencia características importantes do comportamento do detector otimizado.

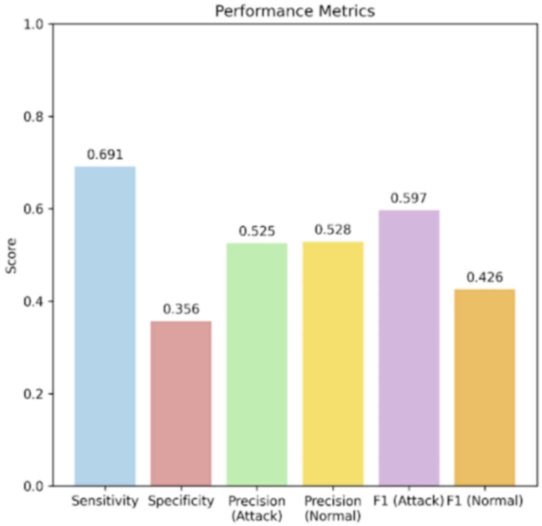

Fig. 5. Métricas de desempenho da melhor configuração obtida. A alta sensibilidade (69,1%) contrasta com a especificidade limitada (35,6%), evidenciando o comportamento conservador característico dos modelos treinados.

A configuração otimizada alcançou sensibilidade de 69,1%, indicando capacidade razoável de detectar ataques FDI quando presentes — um resultado relevante em cenários de segurança, onde falsos negativos representam risco operacional elevado. Por outro lado, a especificidade de 35,6% expõe uma limitação crítica: o sistema gera alarmes falsos em aproximadamente 64,4% das situações normais de operação, valor incompatível com requisitos práticos de confiabilidade.

As métricas de precisão também revelam assimetria: precisão para detecção de ataques de 52,5% e precisão para classificação de tráfego normal de 52,8%. Essa proximidade sugere que o modelo não desenvolveu preferência discriminativa forte por nenhuma classe, operando próximo ao desempenho aleatório. Os valores de F1-score reforçam essa interpretação: F1 para ataques de 59,7% supera modestamente o F1 para tráfego normal de 42,6%, refletindo o viés conservador do detector.

IX. AMPLIAÇÃO PARA POC 2

Os resultados obtidos na POC 1 evidenciaram limitações estruturais tanto na formulação da função de recompensa quanto na capacidade discriminativa do modelo PPO empregado. Apesar da abrangência das configurações temporais exploradas e da otimização de hiperparâmetros, o agente convergiu para comportamento conservador e desempenho próximo ao aleatório, sem progresso significativo ao longo dos episódios de treinamento. Esse diagnóstico orienta diretamente o foco da próxima etapa.

O POC 2 terá como objetivo avançar rumo a resultados comparáveis ao estado da arte em detecção de FDI, aprofundando a investigação das causas do comportamento subótimo observado. O primeiro eixo de exploração consistirá na análise mais criteriosa dos mecanismos de aprendizado envolvidos, buscando identificar se as limitações decorrem de aspectos inerentes à função de recompensa, da arquitetura do modelo, da disponibilidade e qualidade das observações, ou ainda da própria formulação do ambiente de treino. A depender dessas conclusões, serão avaliadas alternativas que incluem a revisão das configurações temporais, a reformulação da função de recompensa ou a substituição do algoritmo de aprendizado por abordagens mais adequadas.

Um segundo eixo abrangerá a comparação sistemática com métodos alternativos. Pretende-se avaliar pelo menos dois algoritmos destacados na Seção VII, além de modelos supervisionados e não supervisionados mais simples, com o objetivo de estabelecer uma linha de base robusta. Essa comparação permitirá determinar se o desempenho limitado do PPO se deve à sua inadequação ao problema ou a características estruturais do ambiente e dos dados. A análise paralela desses métodos fornecerá referência clara sobre comportamentos desejáveis, limites superiores de desempenho e métricas relevantes para direção futura.

Por fim, a investigação de cenários de treinamento mais realistas será conduzida caso haja tempo hábil e resultados suficientes para justificar essa expansão. Isso inclui integração de dinâmicas de tráfego mais complexas, injeção de ruídos mais variados e modelagem de comportamentos adversariais mais sofisticados. Embora essa etapa seja secundária para a POC 2, ela representa caminho natural para aproximação progressiva às condições de operação reais dos sistemas veiculares conectados.

Em conjunto, essas direções estruturam um plano de evolução coerente com os achados da POC 1 e orientado à construção de um detector mais robusto, generalizável e alinhado com práticas contemporâneas de detecção de anomalias em redes veiculares cooperativas.

X. CONCLUSÃO

A POC 1 teve como objetivo investigar a aplicação de *Reinforcement Learning* para detecção de ataques de *False Data Injection* (FDI) em pelotões veiculares, avaliando tanto a formulação básica da função de recompensa quanto extensões temporais projetadas para capturar efeitos de longo prazo nas decisões do agente. Ao longo do desenvolvimento, foram implementadas e analisadas múltiplas estratégias de recompensa, incluindo versões instantâneas, mecanismos temporais com memória e decaimento, e combinações de penalizações e incentivos fundamentadas na dinâmica da formação veicular.

Os experimentos revelaram que, apesar da diversidade de configurações exploradas, o desempenho global dos agentes permaneceu limitado. O PPO apresentou comportamento consistentemente conservador, favorecendo a classificação de observações ambíguas como ataques e resultando em especificidades muito baixas. A incorporação de contexto temporal, embora teoricamente motivada, não produziu melhorias substanciais, indicando que o problema não reside apenas na forma de acumular penalizações ao longo do tempo. A análise das métricas confirmou convergência para acurácia próxima a 52% em todas as variantes, com ausência de trajetória de aprendizado durante os episódios.

Esses achados mostram que a formulação atual — tanto do ambiente quanto do modelo — não é suficiente para produzir um detector com desempenho competitivo. Por outro lado, o processo investigativo trouxe contribuições importantes: esclareceu padrões de comportamento recorrentes, delimitou hipóteses promissoras para investigação futura e consolidou entendimento mais profundo sobre as limitações do algoritmo e do sinal de recompensa empregado. A POC 1 cumpriu, portanto, o papel de mapear os gargalos centrais do problema e estabelecer uma base sólida para avanços posteriores.

A partir desses resultados, a POC 2 concentrará esforços em três direções principais: (i) compreender a fundo as causas do comportamento subótimo observado, incluindo possíveis inadequações do PPO ao problema; (ii) comparar sistematicamente o desempenho com algoritmos alternativos, tanto de RL quanto de aprendizado supervisionado e não supervisionado; e (iii) explorar cenários de treinamento mais realistas, caso o progresso inicial justifique essa expansão. Esses eixos constituem o caminho natural para evolução do trabalho rumo a soluções com desempenho compatível com o estado da arte e operacionalmente viáveis para ambientes veiculares cooperativos.

REFERENCES

[1] N. Hussein, “From da vinci to cybersecurity: tracing the evolution of autonomous vehicles and ensuring safe platooning operations,” *Discover Mechanical Engineering*, vol. 3, no. 1, p. 20, 2024.

[2] S. J. Taylor, F. Ahmad, H. N. Nguyen, and S. A. Shaikh, “Vehicular platoon communication: Architecture, security threats and open challenges,” *Sensors*, vol. 23, no. 1, p. 134, 2023, submission received: 15 November 2022; revised: 12 December 2022; accepted: 20 December 2022; published: 23 December 2022.

[3] R. Sultana, J. Grover, and M. Tripathi, “Intelligent defense strategies: Comprehensive attack detection in vanet with deep reinforcement learning,” *Pervasive and Mobile Computing*, vol. 103, p. 101962, 2024.

[4] A. Borah and A. Paranjothi, “Enhancing VANET security: An unsupervised learning approach for mitigating false information attacks in VANETs,” *Electronics*, vol. 14, no. 1, p. 58, 2025, submission received: 16 November 2024; revised: 23 December 2024; accepted: 24 December 2024; published: 26 December 2024.

[5] S. Raio, K. Corder, T. W. Parker, G. G. Shearer, J. S. Edwards, M. R. Thogaripally, S. J. Park, and F. F. Nelson, “Reinforcement learning as a path to autonomous intelligent cyber-defense agents in vehicle platforms,” *Applied Sciences*, vol. 13, no. 21, p. 11621, 2023, submission received: 18 August 2023; revised: 17 October 2023; accepted: 19 October 2023; published: 24 October 2023.

[6] N. Ahmed, A. Ameli, and H. Naser, “Detection, identification, and mitigation of false data injection attacks in vehicle platooning,” *IEEE Transactions on Vehicular Technology*, vol. 74, no. 1, pp. 1296–1309, 2024.

[7] C. Zhao, J. S. Gill, P. Pisu, and G. Comert, “Detection of false data injection attack in connected and automated vehicles via cloud-based sandboxing,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 7, pp. 9078–9088, 2022, published online: 23 June 2021.

[8] S. D. Vyas and S. Dey, “Reinforcement learning-based adversarial attack generation examples in connected and autonomous vehicles: A case study on vehicular platoons,” *IFAC-PapersOnLine*, vol. 58, no. 28, pp. 78–83, 2024.

[9] S. B. Prathiba, G. Raja, K. Dev, N. Kumar, and M. Guizani, “A hybrid deep reinforcement learning for autonomous vehicles smart-platooning,” *IEEE Transactions on Vehicular Technology*, vol. 70, no. 12, pp. 13 340–13 350, 2021.

[10] H. T. Trinh, S. Bae, and D. Q. Tran, “Deep reinforcement learning for vehicle platooning at a signalized intersection in mixed traffic with partial detection,” *Applied Sciences*, vol. 12, no. 19, p. 10145, 2022, submission received: 19 September 2022; revised: 4 October 2022; accepted: 6 October 2022; published: 9 October 2022.